

THE DO PROGRAMMING LANGUAGE COMPILER

עידו הירש

ת.ז. 214290249

מנחים: ד"ר נילי נוה ומיכאל צ'רנובילסקי

תאריך: 11.11.11

תוכן עניינים

5.....	מבוא
5.....	מטרה
5.....	תיאור המערכת
6.....	ספר השפה Do
7.....	הקדמה
7.....	קצת על Do
7.....	מה יהיה בספר השפה
7.....	אבני השפה
7.....	קבועים – Constants
7.....	טיפוסי קבועים
8.....	משתנים – Variables
8.....	שמות משתנים
8.....	טיפוסי משתנים
8.....	הגדרת משתנים
9.....	ביטויים – Expressions & Statements
9.....	Expression
9.....	Statement
9.....	אופרטורים – Operators
9.....	חשבוניים
9.....	לוגיים
9.....	קשרים לוגיים
10.....	תכולת השפה
10.....	השמה
10.....	תנאים ולולאות
10.....	תנאים – Conditions
11.....	לולאות – Loops
11.....	True & False
12.....	דקדוק השפה
12.....	מהי שפה?
12.....	תחביר השפה
12.....	BNF
12.....	Tokens
13.....	רקע תאורטי
13.....	קומפיילר - Compiler
13.....	מהו קומפיילר?
13.....	Compiler vs. Interpreter
13.....	למה נדרש קומפיילר?
14.....	כיצד עובד קומפיילר?
15.....	שלבי הקומפיילר
15.....	Lexical analysis
15.....	Syntax analysis (Parsing)
15.....	Type checking / Semantic analysis
16.....	Intermediate code generation
16.....	Machine independent code optimization
16.....	Code generation
16.....	Machine dependent code optimization
16.....	Register allocation

16	Assembly, linking and loading
17	Symbol table
17	Error handler
17	מבנה לוגי של קומפיילר
17	Front end
17	Middle end
17	Back end
18	מכונת מצבים
18	מהי מכונת מצבים?
18	מהי שפה פורמלית?
19	סוגים של אוטומטים
19	Chomsky Hierarchy
19	אוטומט סופי
20	אוטומט מחסנית
21	מכונת טיורינג
23	תיאור הבעיה האלגוריתמית
23	ניתוח מילוני – Lexical Analysis
23	ניתוח תחבירי – Syntax Analysis
23	ניתוח סמנטי – Semantic Analysis
24	סקירת אלגוריתמים בתחום הבעיה
24	מונחים
24	Derivation
24	Left-most Derivation
24	Right-most Derivation
25	Left Factoring
26	Parsing Algorithms
26	Top Down Parsing (TDP)
26	Definite Clause Grammar Parsers
27	Recursive Decent Parsing
27	Back tracking
27	דוגמא
28	Predictive parsing
29	LL parser
29	Early parser
30	Bottom Up Parsing (BUP)
30	Shift Reduce
30	Shift step
30	Reduce step
31	דוגמא
32	LR Parser
32	Precedence Parser
32	דוגמא
33	CYK Parser
33	דוגמא
33	Recursive Ascent Parser
34	אסטרטגיה
34	ניתוח מילוני - Lexical Analysis
34	דוגמא לתהליך הניתוח המילוני
35	מטריצת הסמיכויות

35	אלגוריתם לזיהוי אסימון על ידי גרף זה
35	פסאודו קוד
36	האוטומט הסופי של המנתח המילוני
36	אלפבית
36	אוטומט
39	Syntax Analysis – ניתוח תחבירי
39	Action table & Goto table & Stack
39	Action table
39	Goto table
40	דוגמא ל – Action table ו – Goto table
40	מחסנית
41	אלגוריתם הניתוח
41	פסאודו קוד
41	מימוש LR Parser
41	The Dot notation
42	בניית דיאגרמת המעברים
43	בניית הטבלאות
43	מעבר על קשתות - Shift
44	מעבר על מצבים - Reduce
44	First & Follow sets
45	טבלה סופית
45	דוגמא לניתוח בעזרת ה – Parsing table
46	ניתוח השפה Do
46	Tokens
46	Grammar
46	BNF
47	Railroad Diagram
49	דיאגרמת המעברים עבור Grammar השפה
50	טבלאות Action & Goto עבור Grammar השפה
51	Semantic Analysis – ניתוח סמנטי
52	Code Generation

מבוא

מטרה

לבחון את הידע והכישורים שלי בפרויקט בסדר גודל כזה. לפתח אלגוריתמים חכמים ויעילים אשר יפתרו את הבעיות האלגוריתמיות השונות העולות בפרויקט זה, תוך לימוד עצמי של ידע חדש וצבירת ניסיון בנושאים שלא התעסקתי בהם בעבר, כמו מכונות מצבים, עיצוב שפה, ועוד.

תיאור המערכת

המערכת הינה מהדר, Compiler, אשר מתרגם מסמך טקסט המכיל קוד בשפה שאני עיצבתי, Do, לקוד אסמבלי 32 ביט. שפת התכנות היא הגדרה של חוקים תחביריים וסמנטיים, שנועדו להגדיר תהליכי חישוב שיבוצעו על ידי המחשב. הגדרת שפת התכנות היא חלק בלתי נפרד מבניית המהדר – המהדר עושה שימוש בהגדרת השפה כדי לנתח את קטע הקוד שנקלט וכדי בסופו של דבר לייצר את תוכנית היעד.

כאשר מגדירים שפת תכנות, מתייחסים כאמור לשלושה מישורים: האחד מילוני, השני תחבירי והשלישי לשוני.

המישור המילוני מגדיר אילו מילים שייכות לשפה, ואילו לא. לדוגמא, המילה if היא מילה המקובלת בשפת C בעוד שהמילה Hel#@!0 איננה.

המישור התחבירי מגדיר אילו רצפי מילים של השפה הם חוקיים, ואילו הם לא. לדוגמא, הרצף $\text{int } x = 3$ הוא רצף חוקי בשפת C, בעוד שהרצף if x is 5 then איננו חוקי בשפת C.

המישור הלשוני מתייחס למשמעות רצפי המילים, והוא מגדיר חוקים כלליים שחייבים להתקיים בכל רצף מילים בשפה. לדוגמא, חובת ההצהרה – לפני שימוש במשתנה, קיימת חובה להצהיר עליו.

ספר השפה Do

THE DO PROGRAMMING LANGUAGE

Written by Ido Hirsh

FIRST EDITION

הקדמה

קצת על Do

מקור שמה של שפת Do מגיע מקיצור שמי, Ido Hirsh, ומהמילה "תעשה!" באנגלית, מילה המעוררת מוטיבציה לעבודה ועשייה.

שפת Do דומה בסינטקס שלה לשפות התכנות C ו-C++.

מה יהיה בספר השפה

בספר השפה תתואר שפת התכנות Do. יתוארו אבני השפה, תכולת השפה, ודקדוק השפה.

אבני השפה

קבועים – Constants

קבוע הוא ערך המופיע ישירות בקוד התוכנית.

קבוע יכול להיות מטיפוסים שונים – מספר שלם, תו.

טיפוסו של הקבוע נקבע על ידי המהדר (Compiler) בהתאם לערכו.

דוגמא: $int\ x = 81$

בדוגמא שלעיל 81 הוא קבוע, אשר יובן על ידי ה- Compiler כקבוע מטיפוס int, מספר שלם.

טיפוסי קבועים

- קבוע מטיפוס מספר שלם - **int**.

על מנת להגדיר קבוע מסוג int נכתוב את ערכו ישירות בקוד התוכנית:

○ דוגמא:

$a / 2$

בדוגמא זו 2 הוא קבוע ו- a הוא שם משתנה כלשהו.

- קבוע מטיפוס תו - **char**.

הגדרת קבוע מסוג char תהיה בתוך שני גרשים בודדים:

○ דוגמאות להגדרה:

$char\ ch = '5'$

הערך של התו 5 ייכנס אל תוך המשתנה ששמו ch.

משתנים – Variables

משתנה מייצג מקום בזיכרון בו אפשר לשמור ערכים.

מקום זה בזיכרון מיוצג על ידי שם המשתנה (Variable-name), שנקרא גם מזהה (Identifier).

שמות משתנים

1. שם משתנה הוא רצף של אותיות בשפה האנגלית, ספרות, והתו '_' (Underscore). רצף זה חייב להתחיל באות בשפה האנגלית או בתו '_'.
2. אורכו של מזהה אינו מוגבל.
3. אין להשתמש במילים שמורות כמזהים.
4. קיימת הבחנה בין אותיות גדולות וקטנות (Case sensitive).

טיפוסי משתנים

לכל משתנה בשפה do יש גם טיפוס (Data-type) אשר מציין את סוג הערכים שהוא יכול להכיל.

ישנם שני סוגים של טיפוסי משתנים:

- **int** – משתנה מטיפוס מספר שלם.
 - מכיל ערכים מסוג מספרים שלמים. 1, -15, 79, 0 וכו'.
- **char** – משתנה מטיפוס תו.
 - מכיל ערכים מסוג תו. a, g, 0, 7, f וכו'.

הגדרת משתנים

הגדרה כללית של משתנה:

<Data-type> <Identifier>;

דוגמאות:

int x;

char c;

ביטויים – Expressions & Statements

Expression

יחידה תחבירית בשפת תכנות שניתן להעריכה על מנת לקבוע את ערכה. שילוב של אחד או יותר קבועים, משתנים, פונקציות, אופרטורים (Operators), ו- Expression נוספים, שהשפה מפרשת (לפי הכללים של קדימות ושיוך), ומחשבת כדי לייצר ("להחזיר") ערך. תהליך זה, עבור ביטויים מתמטיים, נקרא הערכה (Evaluation).

בפשטות, הערך המתקבל הוא בדרך כלל אחד מהסוגים הפרימיטיביים השונים, כמו ערך מספרי, ערך בוליאני וכו'.

דוגמאות ל- Expressions:

- $3 + 15$
- 4
- $(x - 5) / y$
- $7 \leq 22$
- $x \% 2 == 0$
- $(x + 15) < 3 * (y - 4)$

Statement

יחידה תחבירית בשפת תכנות המבטאת פעולה כלשהי שיש לבצע. תכנית הנכתבת בשפה כזו נוצרת על ידי רצף של אחד או יותר Statements.

בשונה מ- Expression, Statement לא מוערכת לכדי ערך.

ל- Statement יכולים להיות רכיבים פנימיים (למשל Expressions).

דוגמאות ל- Statements:

- תנאים – *if, else*
- לולאות – *while*
- הצהרה על משתנה – *int x;*
- השמת ערך למשתנה – *x = 4;*

אופרטורים – Operators

חשבוניים

- חיבור – $+$
- חיסור – $-$
- כפל – $*$
- חילוק – $/$
- שארית – $\%$

לוגיים

- שווה ל – $==$
- גדול מ – $>$
- קטן מ – $<$
- גדול או שווה ל – $>=$
- קטן או שווה ל – $<=$
- not – $!$

קשרים לוגיים

- or – $||$
- and – $\&\&$

תכולת השפה

בחלק זה תתואר תכולת השפה ואיך כל חלק בשפה נכתב בצורה נכונה מבחינה דקדוקית.

כל פקודה בשפה Do תסתיים עם נקודה פסיק ;

למעט תנאים, לולאות, ו - { }

השמה

כפי שציינתי לעיל משתנה הוא מקום בזיכרון בו אפשר לשמור ערך. השמה מאפשרת לנו לשמור את הערך הרצוי במקום זה בזיכרון.

הערך יכול להיות קבוע / משתנה / ביטוי (Expression).

סימול של השמה מבוצע באמצעות סימן השווה - =

- הגדרה כללית להשמה:

<Identifier> = <Expression>;

על מנת שההשמה תהיה חוקית, טיפוס המשתנה אליו עושים את ההשמה, כלומר ה - <Data-type>

של ה - <Identifier> צריך לתאם לטיפוס הערך המושם, כלומר ה - <Data-type> של ה - <Expression>.

- דוגמאות:

num = -17;

ch = 'h';

תנאים ולולאות

תנאים ולולאות הם חלקי קוד המתבצעים כתלות באם ביטוי מסוים הוא אמת או שקר.

תנאים – Conditions

לתנאי יכולים להיות שני חלקים:

- if
- else

אם הביטוי נותן תוצאת אמת, הקוד שבחלק של ה - if יתבצע.

ואם נותן תוצאת שקר, הקוד שבחלק של ה - if לא יתבצע.

אם יש חלק של else, הוא יתבצע כאשר הביטוי נותן תוצאה שקרית.

חלקים אלו של ה - if וה - else יתבצעו 0 או 1 פעמים.

בכל מקרה, לאחר ביצוע התנאי התוכנית תמשיך לקוד שנמצא אחריו.

- דוגמא להגדרת תנאי בעזרת שימוש ב – if בלבד:

```
if (<Expression>)
{
    Do if <Expression> is True
}
...
```

- דוגמא להגדרת תנאי בעזרת שימוש ב – if ו - else:

```
if (<Expression>)
{
    Do if <Expression> is True
}
else
{
    Do if <Expression> is False
}
...
```

לולאות – Loops

לולאה דומה מאוד במבנה שלה לתנאי, if, אך ההבדל היחיד הוא שחלק הקוד שבתוך הלולאה מתבצע **כל עוד** התנאי תקף (כל עוד הביטוי נותן תוצאת אמת), ולא דווקא 0 או 1 פעמים. כלומר לולאה יכולה להתבצע מספר רב של פעמים.

- while

דוגמא כללית להגדרת לולאה בעזרת שימוש ב - while:

```
while (<Expression>)
{
    Do while <Expression> is True
}
...
```

True & False

- False - false הוא הערך 0.

False = 0

- True - true הוא כל ערך השונה מ - 0.

True != 0

דקדוק השפה

לאחר שהגדרתי את אבני השפה ותכולת השפה, כעת אגדיר את תחביר / דקדוק השפה. ה – Grammar של השפה.

מהי שפה?

שפה היא אוסף המשפטים שמצייתים לחוקים המוגדרים בתחביר של השפה. משפטים אלו מורכבים מהמילים / האסימונים (Tokens) המוגדרים בשפה. (ראה פרק [רקע תאורטי – מהי שפה פורמלית?](#) עבור הגדרה של שפה פורמלית).

תחביר השפה

תחביר השפה do, כמו רוב שפות התכנות, הוא תחביר חופשי הקשר (Context free grammar). הדקדוק מורכב מ – Terminals ו Non-Terminals. הסימנים (Terminals) הם המילים (Tokens) שנקלטו כקלט מקטע הקוד, בעוד שהמשתנים (Non-Terminals) הם רצפי סימנים ומשתנים. תחביר השפה מוגדר באמצעות שילוב הסימנים והמשתנים, בכללים שנקראים כללי יצירה (Production rules). כללי היצירה בעצם מגדירים את המשתנים, באמצעות הסימנים המוגדרים בשפה ומשתנים אחרים.

BNF

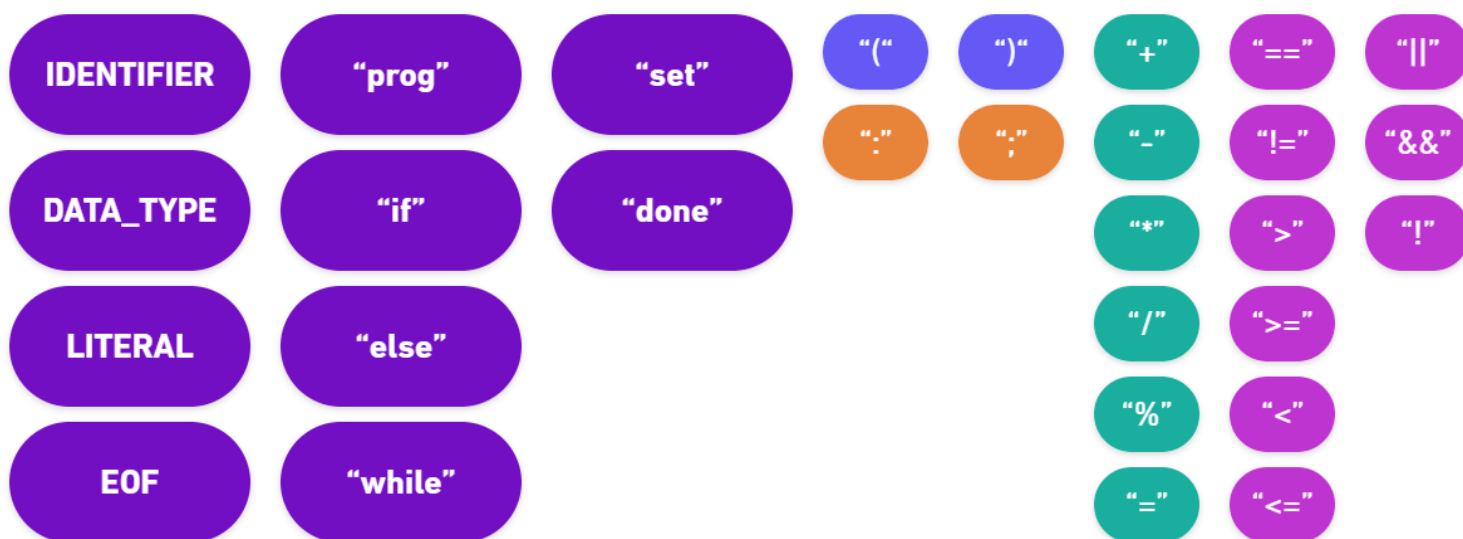
Backus-Naur Form היא צורת כתיבה פורמלית (Notation) עבור תיאור Grammars של שפות נטולות הקשר (Context free languages). צורת כתיבה זו משמשת לעיתים קרובות לתיאור שפות תכנות (שהן לרוב שפות נטולות הקשר).

BNF עוזר לכתוב בצורה חד-חד משמעית את כללי ה – Grammar של שפה מסוימת, באופן יחסית קל וקריא.

Tokens

להלן האסימונים, ה – Tokens של השפה Do:

Tokens



רקע תאורטי

קומפיילר - Compiler

מהו קומפיילר

תוכנת מחשב אשר מתרגמת קוד מקור הכתוב בשפת תכנות אחת לקוד הכתוב בשפת תכנות אחרת, ללא שינוי המשמעות של קוד המקור. לרוב מתרגם משפה עילית (C, C++, Java), לשפת מכונה.

הקומפיילר גם מייעל ומשפר את קוד המקור כמה שניתן. כמו כן, מתריע על השגיאות / אזהרות שמצא, ומציע הצעות לפתרונות שלדעתו יפתרו שגיאות / אזהרות אלו.

Compiler vs. Interpreter

ישנם שני אופני עבודה עיקריים של קומפיילר: תרגום כל קוד המקור לכדי יחידת הרצה אחת (Compiler), או תרגום כל פקודה בנפרד בקוד המקור תוך כדי ריצת התוכנית (Interpreter).

כפי שצוין לעיל, Compiler, עובר על כל קוד המקור לפני הריצה, בודק את תקינותו, ומתרגם וממיר אותו ליחידת הרצה אחת בשפת מכונה. שפות שמתורגמות על ידי Compiler נקראות שפות מקומפלות. דוגמאות לשפות מקומפלות הן C, C++, Java ועוד.

בניגוד ל – Compiler, ה – Interpreter מתרגם וממיר כל פקודה בנפרד בקוד המקור לפקודות בשפת מכונה, תוך כדי ריצת התוכנית, ללא בדיקת תקינות הקוד לפני הריצה. שפות שמתורגמות על Interpreter נקראות שפות סקריפטים. דוגמאות לשפות אלו הן Python, JavaScript ועוד.

למה נדרש קומפיילר

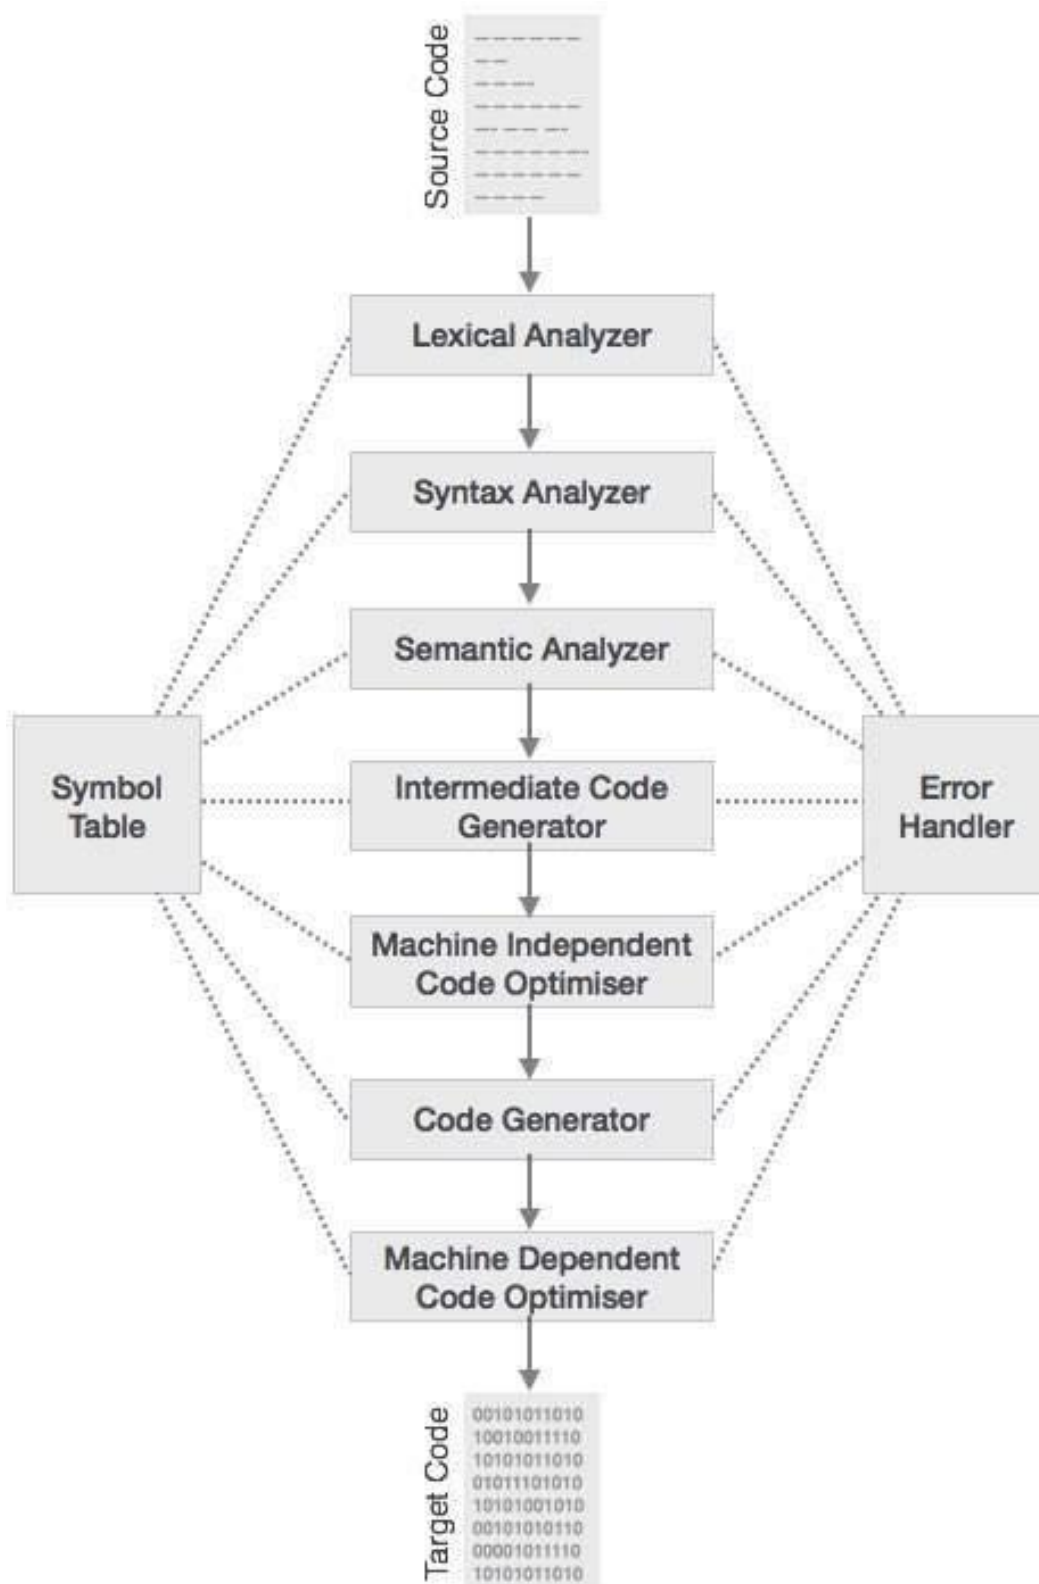
מכיוון שלבני האדם קל יותר לכתוב קוד בשפות תכנות עיליות אשר יותר קרובות אליהם (יותר קרובות לאנגלית), מאשר לכתוב קוד בשפת מכונה, אנו משתמשים בשפות עיליות אלו לכתוב קוד. אך המחשב אינו מבין שפות עיליות אלו, הוא מבין רק קוד בשפת מכונה.

בשביל לגשר על הפער בין בני האדם לבין המכונה, צריך קומפיילר. שיתרגם את מה שאנו מתכוונים כאשר אנו כותבים קוד בשפה עילית לשפה שהמחשב יבין, שפת מכונה.

כיצד עובד קומפיילר

תהליך הקומפילציה הוא תהליך מורכב, ולכן מוטב לחלק אותו לשלבים. הקומפיילר עובד כך שכל שלב מקבל כקלט את התוצאה של השלב הקודם.

להלן דיאגרמה של השלבים:



שלבי הקומפיילר

כפי שציינתי לעיל תהליך הקומפילציה הוא תהליך מורכב, ולכן מוטב לחלק אותו לשלבים. מקובל לחלק כל שלב למודול עצמאי.

להלן חלוקה נפוצה של מודולים:

Lexical analysis

השלב הראשון בתהליך הקומפילציה הוא הניתוח המילוני, ה- `lexer`.

מטרתו של שלב זה הוא לעבור על קוד המקור (`source code`) שהוא בעצם אוסף של תווים בתוך קובץ, ולהוציא מאוסף תווים זה טוקנים, `tokens`, הנמצאים בשפה. הטוקנים הם אבני השפה. לדוגמא המילה השמורה `int` בשפת C, או קבוע מסוג מספר שלם, או שם של משתנה כלשהו.

כבר בשלב הראשון של הקומפילציה יכולות להיווצר שגיאות. סוג השגיאות שיתפסו כאן יהיו שגיאות מילוניות. דוגמא לטעות מילונית בשפת C: `int x = 1q2;`

התו `q` לא יכול להימצא באמצע הגדרת מספר. ולכן תוצג שגיאה.

ה- `lexer` מעביר את ה- `tokens` לשלב הבא בקומפילציה, ה- `parser`.

Syntax analysis (Parsing)

השלב השני בתהליך הקומפילציה הוא הניתוח התחבירי, ה- `parser`.

מטרתו של שלב זה הוא להבין, מתוך הטוקנים שה- `lexer` מספק לו, האם הקוד שהמשתמש כתב, תקין מבחינה תחבירית בשפה. ה- `parser` עובד על פי ה- `grammar` של השפה אותה הוא מקמפל. הוא בודק לפי חוקי ה- `grammar` האם הקוד הנתון יכול להתקבל כקוד תקין בשפה. ה- `grammar` לרוב הוא `context-free grammar`.

גם בשלב זה של הקומפילציה יכולות להיווצר שגיאות. סוג השגיאות שיכולות להיתפס כאן הן שגיאות תחביריות.

דוגמא לטעות תחבירית בשפת C: `x int = 5;`

על פי הגדרת השפה של שפת C על מנת להגדיר משתנה צריך לכתוב את טיפוס המשתנה, אחריו שמו, ואז אם רוצים אפשר לעשות השמה של ערך. כיוון שהדוגמא לעיל לא תואמת ל- `grammar` של השפה, תיווצר שגיאה תחבירית.

שלב זה יוצר את ה- `syntax tree` של התוכנית. ה- `syntax tree` (נקרא גם `abstract syntax tree`), הוא בעצם ארגון רצף הטוקנים שמגיעים מה- `lexer` לתוך מבנה מאורגן בצורת עץ.

העץ נבנה על פי חוקי ה- `grammar`. שלב זה משמיט חלק מאבני השפה, לדוגמא סוגריים, מכיוון שהמבנה של העץ עצמו אומר לנו מה סדר הפעולות לביצוע בשלבים הבאים.

לאחר ששלב זה מסתיים, ה- `syntax tree` יועבר לשלב הבא, הניתוח הסמנטי.

Type checking / Semantic analysis

השלב השלישי בתהליך הקומפילציה הוא הניתוח הסמנטי.

הוא מקבל את ה- `syntax tree` מהשלב הקודם (`parser`) ומטרתו העיקרית היא לבדוק את הרצף הלוגי של התוכנית. האם יש חוסר תאימות בין סוגי משתנים? האם יש שימוש במשתנה שלא הוכרז?

לכן דוגמא לשגיאות שיכולות להיווצר בשלב זה הן שגיאות של חוסר התאמת טיפוסים, שימוש במשתנה לא מוגדר וכו'.

שלב זה מפיק בסופו של דבר את עץ הניתוח, שהוא העץ התחבירי רק מפושט יותר, לאחר בדיקה של התאמת משתנים, שימוש במשתנים לא מוכרזים וכו'.

הבדיקה הסמנטית היא בדיקת הקלט האחרונה בתהליך הקומפילציה, ולכן עץ הניתוח שנפלט ממנה מייצג תוכנית תקינה.

Intermediate code generation

השלב הרביעי בתהליך הקומפילציה הוא שלב יצירת קוד הביניים.

שלב זה מקבל את ה – semantic tree מהשלב הקודם, כך שבשלב זה ניתן לדעת שהתוכנית תקינה.

לאחר ניתוח סמנטי, המהדר יוצר קוד ביניים של קוד המקור עבור מכונת המטרה. קוד זה מייצג תוכנית עבור מכונה מופשטת כלשהי. בין השפה העילית לבין שפת המכונה. יש ליצור קוד ביניים זה בצורה כזו שתקל על התרגום לקוד מכונת היעד.

Machine independent code optimization

שלב זה מקבל את הקוד שיוצר בשלב הקודם, ומטרתו לשפר וליעל אותו. כמו סידור מחדש של שורות קוד, והסרת שורות קוד לא נחוצות, כדי לבזבז כמה שפחות משאבים, ולהפוך את הקוד ליעיל יותר הן מבחינת זמן והן מבחינת מקום.

Code generation

שלב זה לוקח את קוד הביניים מהשלב הקודם ומתרגם אותו לקוד בשפת מכונה.

Machine dependent code optimization

השלב האחרון בתהליך הקומפילציה, מטרתו של שלב זה היא לשפר וליעל את קוד המכונה שנוצר בשלב הקודם. בדומה ל – machine independent code optimizer, מטרתו להפוך את הקוד ליעיל יותר הן מבחינת זמן והן מבחינת מקום.

נוסף על כך, ישנם עוד מודולים שכיחים:

Register allocation

לתוכנית יש מספר ערכים שהיא צריכה לשמור במהלך הריצה שלה. ייתכן שארכיטקטורת מכונת היעד לא תאפשר לכל הערכים להישמר בזיכרון המעבד, או ה – registers. השלב של ה – machine depended code generator, מחליט אילו ערכים לשמור ב – registers, ואילו registers ישמרו ערכים אלו.

Assembly, linking and loading

אסמבלר מתרגם שפת אסמבלי לשפת מכונה. הוא יוצר מקובץ asm שמכיל שפת אסמבלי, קובץ object. קובץ object מכיל הוראות בשפת מכונה, כמו גם המידע הדרוש על איפה צריך לשים את ההוראות האלה בזיכרון.

לינקר מחבר כמה קבצי object לקובץ exe אחד.

כל הקבצים שהוא מחבר יכולים להיות מקומפלים על ידי אסמבלרים שונים.

משימתו העיקרית של הלינקר היא לקבוע את המיקום בזיכרון של כל אחד מהקבצים בעת הטעינה שלהם לזיכרון (על ידי ה – Loader), כך שההוראות מקבצי ה – obj השונים יתבצעו בסדר הגיוני בעת הריצה.

ה – loader הוא חלק ממערכת ההפעלה שאחראי על הטעינה של קבצי הרצה (exe) לזיכרון, והביצוע שלהם.

הוא מחשב את גודל התוכנית ומקצה לה מספיק מקום בזיכרון. הוא גם מאתחל מספר רגיסטרים שונים שיתחילו את תהליך הביצוע/הרצה של התוכנית.

Symbol table

ה – Symbol table או טבלת הסמלים, מכילה רשומה עבור כל Identifier (מזהה) עם שדות עבור התכונות של אותו המזהה.

טבלה זו עוזרת לקומפיילר למצוא רשומה של מזהה כלשהו בתוכנית ולקבל את הפרטים עליו באופן מהיר יחסית.

ה – Symbol table עוזרת גם ב – Scope management.

טבלה זו לוקחת חלק בכל אחד מהשלבים שצוינו לעיל, ומתעדכנת בהתאם.

Error handler

כפי שכתבתי בתיאור השלבים של הקומפיילר, בכל שלב ושלב בתהליך הקומפילציה יכולות להיווצר שגיאות.

בשביל כך יש את ה – Error handler.

השגיאות שמתגלות מדווחות ל – Error handler והוא מדווח, ומציג אותן חזרה למתכנת בתצורה של הודעה. אם לקומפיילר יש הצעה מסוימת לפתרון הבעיה, גם היא תוצג בהודעה.

מבנה לוגי של קומפיילר

ניתן לחלק את הקומפיילר לשלושה חלקים לוגיים: back end, middle end, front end.

Front end

עובר על קוד המקור ומנתח אותו.

בחלק זה משתתפים ה – Lexical analysis, ה – Syntax analysis (Parsing) וה – Semantic analysis.

Middle end

אחראי על ייעול הקוד על מנת לשפר את ביצועי הקו.

בחלק זה משתתפים ה – Intermediate code generation וה – Machine independent code optimization.

Back end

אחראי על ייעול ויצירת הקוד המובן לשפת מכונה.

בחלק זה משתתפים ה – Machine dependent code generation וה – Machine dependent code optimization.

מכונת מצבים

מהי מכונת מצבים?

מכונת מצבים (לעיתים נקראת גם אוטומט) היא מודל מתמטי חישוב, מכונה אבסטרקטית, אשר נמצאת במצב אחד מתוך אוסף סופי של מצבים בכל רגע נתון, כך שהמעבר בין מצב למצב מותנה בקלט, והקלט מוגבל לא"ב המוגדר מראש. (כלומר, תווי הקלט שהאוטומט מקבל מוגדרים מראש). האוטומט מקבל שפה פורמלית.

מהי שפה פורמלית?

שפה פורמלית, Formal Language, בנויה ממילים שהתווים שלהן נמצאים מעל א"ב מוגדר, והמילים עצמן בנויות מאוסף מוגדר היטב של חוקים המרכיב תווים מא"ב זה.

הא"ב של שפה פורמלית בנוי מאותיות, תווים, סמלים או אסימונים, המחוברים יחד לכדי יצירת מחרוזות בשפה. כל מחרוזת המורכבת מא"ב זה נקראת מילה, ואוסף המילים השייכות לשפה פורמלית נקראות Well-Formed Words.

הא"ב של שפה מתואר כך: $\Sigma = \{ 0, 1, 2, b, \#, \dots \}$, כך שהתווים הכלולים בא"ב Σ נמצאים בתוך הסוגריים המסולסלים.

אוסף כל המילים מעל הא"ב Σ מסומן בדרך כלל Σ^* . אורך מילה בשפה נקבע על פי מספר התווים מתוך הא"ב מהם היא מורכבת. לכל שפה יש רק מילה אחת באורך 0 והיא המילה הריקה, לרוב מסומנת, ϵ , e . על ידי שרשור שתי מילים בשפה ניתן ליצור מילה חדשה שהאורך שלה יהיה הסכום של שתי המילים. שרשור מילה עם ϵ ישאיר את המילה כמו שהיא.

שפה פורמלית L מעל הא"ב Σ היא תת-אוסף של Σ^* . כלומר, אוסף מילים מעל אותו הא"ב.

כתיבה פורמלית של שפה: $L = \{ w \in \Sigma^* \mid \text{Condition} \}$


כלומר השפה מוגדרת ככל המילים הנמצאות מעל הא"ב של השפה העומדות בתנאי (Condition).

ישנם מספר סוגים של שפות פורמליות: שפות רגולריות, שפות חופשיות הקשר, שפות תלויות הקשר, כך שכל אחת מורכבת יותר מהשנייה, ומאפשרת קבלת מחרוזות מורכבות יותר מקודמתה. ההיררכיה בין סוגי השפות מתוארת על פי ה – Chomsky Hierarchy, כפי שיוצג בהמשך בהסבר על סוגים של אוטומטים.

סוגים של אוטומטים

ישנם סוגים שונים של אוטומטים, כך שיש אוטומטים חזקים יותר, המסוגלים לקבל שפות מורכבות יותר ולפתור בעיות מורכבות יותר, ויש אוטומטים חלשים יותר, כלומר מסוגלים לקבל רק סוגים מסוימים של שפות, ולפתור רק סוגים מסוימים של בעיות. סוגי האוטומטים מסודרים על פי ה-Chomsky Hierarchy, היררכיה של אוטומטיים ושפות פורמליות שהגדיר Noam Chomsky, החל מהאוטומט החלש ביותר, אוטומט סופי, לחזק ביותר, מכונת טיורינג, שהיא המודל התאורטי המתאר את המחשב המודרני שלנו כיום.

Chomsky Hierarchy




אוטומט סופי

אוטומט סופי, Finite Automaton (FA) / Finite State Machine (FSM), הוא מכונת מצבים אשר יכולה להימצא במצב אחד מתוך אוסף סופי של מצבים בכל רגע נתון, והמעבר בין מצב למצב מותנה רק על ידי תווי הקלט.

אוטומט סופי מאופיין בכך שהוא מקבל רק שפות רגולריות, Regular Languages. שפה רגולרית היא שפה פורמלית שיכולה להיות מתוארת על ידי Regular Expression (Regex), והיא נמצאת במקום הנמוך ביותר בהיררכיה של צ'ומסקי (Chomsky Hierarchy).

דיאגרמה המתארת אוטומט סופי מעל הא"ב $\Sigma = \{0, 1\}$ המקבל רק מחרוזות עם מספר זוגי של אפסים



העיגולים בדיאגרמה, S_1 ו- S_2 , מתארים מצבים, כך שעיגול כפול, כמו במקרה של S_1 נקרא מצב מקבל. אם האוטומט נעצר על מצב מקבל לאחר שסיים לעבור על כל תווי הקלט, משמע שהקלט הוא חלק מהשפה. עבור כל מקרה אחר, הקלט לא חלק מהשפה.

החיצים בדיאגרמה מתארים את המעברים בין המצבים השונים של האוטומט כתלות בקלט. לדוגמא, על מנת לעבור ממצב S_1 למצב S_2 אנו חייבים לקלוט 0. עבור קלט 1 אנו נשאר במצב S_1 . החץ היחיד בדיאגרמה שרק מסתיים במצב ולא מתחיל בשום מצב הוא החץ המצביע על המצב ההתחלתי של האוטומט. לכל אוטומט יש מצב התחלתי ממנו מתחיל האוטומט לעבוד.

שוב, מחרוזת תחשב כחלק מהשפה אם ורק אם האוטומט סיים את עבודתו במצב מקבל, ורק לאחר שעבר על כל תווי הקלט.

אוטומט מחסנית


אוטומט מחסנית, Push-Down Automaton (PDA), הוא מכונת מצבים אשר נעזרת במחסנית לביצוע עבודתה, והמעבר בין מצבים מותנה לא רק על ידי תווי הקלט, אלא גם על ידי מה שנמצא בראש המחסנית. הפעולות היחידות האפשריות על המחסנית הם Push ו- Pop של איברים הנמצאים בא"ב של המחסנית.

אוטומט מחסנית מאופיין בכך שהוא מקבל שפות חופשיות הקשר, Context Free Languages. ישנו קשר הדוק בין אוטומט מחסנית ל- CFL. כל Context Free Grammar המתאר Context Free Language יכול להיות מתואר על ידי אוטומט מחסנית.


כיוון שכעת ישנה גם מחסנית, PDA מוגדרת כעת על ידי 7 דברים:

- Q – אוסף סופי של מצבים
- Σ – א"ב של הקלט
- Γ – א"ב של המחסנית
- δ – פונקציית מעבר, אוסף סופי של המעברים האפשריים מעל הא"ב של הקלט והא"ב של המחסנית
- q_0 – המצב בו מתחיל האוטומט
- Z – הסמל ההתחלתי על המחסנית
- F – אוסף המצבים המקבלים באוטומט

דיאגרמה המתארת אוטומט מחסנית באופן אבסטרקטי



דיאגרמה המתארת אוטומט מחסנית המקבל את השפה $L = \{0^n 1^n \mid n \geq 0\}$ (מחרוזות עם מספר שווה של 0 ו-1)



ישנן שתי דרכים מקובלות בהן מחרוזות תתקבל באוטומט מחסנית. אחת אומרת שאם ורק אם האוטומט סיים במצב מקבל (נמצא ב- F), ונקראו כל תווי הקלט המחרוזות תתקבל. השנייה אומרת שאם ורק אם האוטומט סיים כאשר המחסנית ריקה, ונקראו כל תווי הקלט המחרוזות תתקבל. הראשונה משתמש בזיכרון הפנימי של המכונה, הלוא הם המצבים, והשנייה משתמש בזיכרון החיצוני של המכונה, הלוא היא המחסנית.

מכונת טיורינג

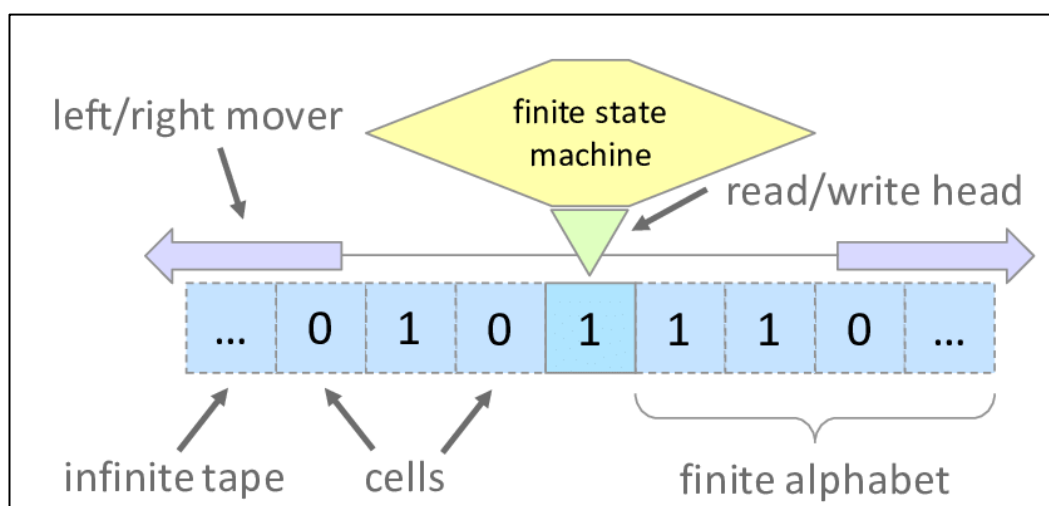
מכונת טיורינג, Turing Machine, היא מודל חישובי מתמטי אשר באמצעותו ניתן לתאר באופן מופשט את פעולתו של מחשב.

מכונת טיורינג מתארת בצורה פורמלית-מתמטית, כיצד ניתן לבצע פעולות חישוביות שונות כגון זיהוי מילים השייכות לשפה פורמלית, ביצוע פעולות חיפוש ומיון בקלט ועוד. מכונת טיורינג היא האוטומט החזק ביותר לביצוע חישובים והיא אינה מוגבלת לסוג מסוים של שפה. כל בעיה הניתנת לפתרון יכולה להיפתר באמצעות מכונת טיורינג, וניתן להוכיח כי קיימות שפות, או במילים אחרות קיימות בעיות, אשר אינן ניתנות לחישוב במכונת טיורינג, ולכן לא ניתנות לחישוב באמצעות כל מחשב. המושג "חישוב" מוגדר לעיתים על סמך פעולות הניתנות לביצוע באמצעות מכונת טיורינג.

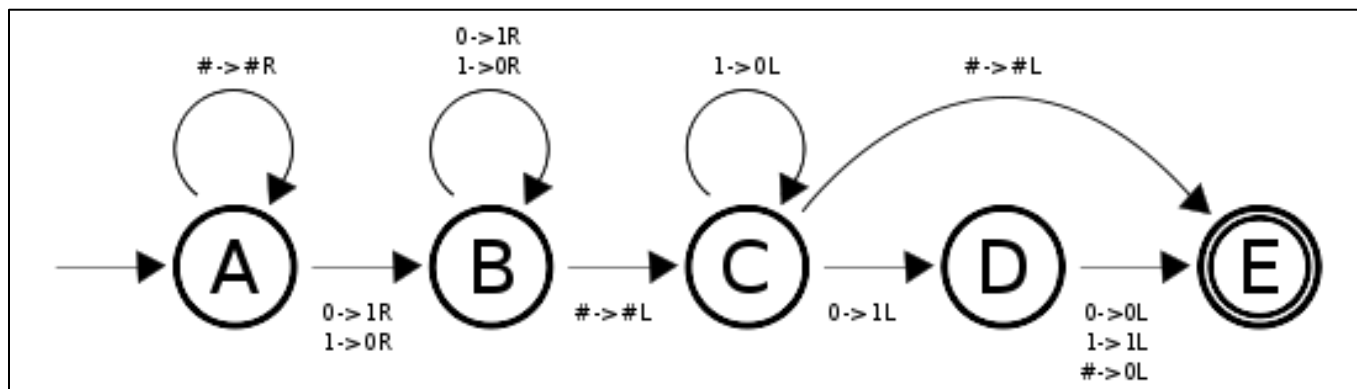
מכונת טיורינג מתוארת באופן דמיוני כסרט אינסופי של תאים, וראש קורא-כותב בעל זיכרון סופי, היכול לקרוא את תוכנו של התא שמעליו הוא ממוקם, לכתוב באותו התא וכן לנוע ימינה או שמאלה על גבי הסרט. המכונה מקבלת את הקלט שלה באמצעות הסרט, עליו היא יכולה גם לכתוב, ולזוז כרצונה לכל נקודה על גביו.

את המודל הציע אלן טיורינג בשנת 1936, טרם המצאת המחשב המודרני, כדי ליצור הגדרה מתמטית מדויקת של אלגוריתם, או "תהליך מכני" חישובי.

דיאגרמה אבסטרקטית המתארת את אופן פעולתה של מכונת טיורינג



אוטומט המתאר מכונת טיורינג הקוראת מספר בינארי וכותבת את המספר הנגדי לו בשיטת המשלים ל - 2



כפי שציינתי לעיל, מכונת טיורינג היא האוטומט החזק ביותר, המחשב המודרני יכול להיות מתואר בעזרתה, היא אינה מוגבלת לאף שפה או בעיה כל עוד היא ניתנת לפתרון, ואם בעיה אינה ניתנת לפתרון על ידי מכונת טיורינג היא לא יכולה להיפתר על ידי שום מחשב.

מכונת טיורינג מגדירה את הגבול בין הבעיות שאנו יכולים ולא יכולים לפתור על ידי מחשבים.

תיאור הבעיה האלגוריתמית

בפרק זה אציג את הבעיות האלגוריתמיות העולות בכל שלב מרכזי בתהליך הקומפילציה, אנתח אותן ואתן דוגמאות.

ניתוח מילוני – Lexical Analysis

כיצד נוכל לפרש בצורה חד משמעית את רצף התווים כ – Token מסוים? למשל, כאשר נראה את התו '=', נוכל להניח שמדובר בהשמה של ערך לתוך משתנה, אך מה אם מייד אחריו יופיע עוד פעם '='? נצטרך להתייחס לשני התווים כ – Token אחד המייצג השוואה.

ניתוח תחבירי – Syntax Analysis

כפי שציינתי לעיל, המנתח המילוני (Lexer) מזרים טוקנים, מילים תקינות הכלולות בשפה, אל המנתח התחבירי (Parser). ה – Parser צריך למצוא היגיון בסדר הטוקנים ולבנות ממנו עץ אשר ייצג תוכנית הגיונית.

על מנת לבנות עץ מדויק, יש להגדיר "נוסחאות" מדויקות שייצגו את השפה, וההיגיון שבה. וכפי שציינתי בפרק של תיאור השפה Do, מקובל לתאר נוסחאות אלו בצורת BNF.

מאחר ומדובר בעץ, ולכל צומת בעץ יש תכונות שונות ו – "ילדים" שונים זה מזה, צריך למצוא דרך לשמור על התכונות הייחודיות של כל אחד מהם, ועדיין לשמור על היכולת להסתכל עליהם כמכלול.

עוד אתגר מעבר להגדרת השפה, הוא "מצבים מקבלים". למשל ב – C#, מה קורה כאשר המצב הנוכחי הוא Statement, והטוקן הנוכחי הוא Identifier? איך נדע האם לצפות להשמה (Assignment), כמו "X = 3;", או לקריאה לפעולה של עצם כמו "X.Foo()"? אם המצב הנוכחי הוא הכרזה על משתנה, והטוקן הנוכחי הוא Identifier, איך נדע האם לצפות ל – Semicolon, או לפסיק?

איך נוכל לדעת תמיד למה לצפות באופן מדויק?

ניתוח סמנטי – Semantic Analysis

עד כה ראינו רצף מאוד הגיוני. המנתח המילוני בודק טוקנים ומוודא שכולם בשפה, המנתח התחבירי מרכיבים מטוקנים אלו משפטים ובודק שמשפטים אלו תקינים בשפה. וכעת המנתח הלשוני צריך לקבל את התוכנית בצורת העץ התחבירי ולבדוק האם היא הגיונית. פה ייבדק הרצף הלוגי של התוכנית, האם יש שימוש במשתנה שלא הוכרז? האם יש חוסר תאימות בין סוגי משתנים?

בכדי לפענח את העץ התחבירי, נצטרך למצוא שיטה יעילה לעבור עליו, ולפשט אותו. כיצד נזהה את הטיפוס של כל צומת בעץ? כיצד נסרוק את העץ בצורה שתאפשר לנו לקבל את הערכים הנורשים מאחיו, הוריו וילדיו?

העץ לאחר הניתוח הלשוני נבדל מעץ הניתוח התחבירי בכך שהוא מכיל אך ורק את מה שנדרש על ידי המתרגם לתרגום הקוד. העץ התחבירי פשוט יותר גם מבנית וגם רעיונית. הוא ממוקד וללא צמתים מקשרים, ומטרתו היחידה היא לייצג את התוכנית במבנה שיאפשר בקלות יחסית לתרגמו לייצוג ביניים.

ושוב, כפי שציינתי כבר קודם, המנתח הלשוני (הבדיקה הסמנטית) היא בדיקת הקלט האחרונה בתהליך ההידור, ולכן העץ שנפלט ממנה מייצג תוכנית תקינה.

סקירת אלגוריתמים בתחום הבעיה

תהליך הניתוח התחבירי, ה-Parsing, הוא התהליך המשמעותי והמורכב ביותר מבחינה אלגוריתמית ורעיונית בתהליך הקומפילציה. כעת אציג שיטות שונות ואלגוריתמים שונים הנפוצים בשלב זה.

מונחים

כמה מונחים שאשתמש בהם בתיאור האלגוריתמים.

Derivation

בעברית, גזרה, היא בעצם רצף של Production rules, על מנת לקבל את מחרוזת הקלט.

במהלך תהליך ה-Parsing אנו בעצם מקבלים שתי החלטות עבור קלט מסוים:

1. החלטה על ה-Non-terminal אשר יוחלף.
2. ההחלטה על כלל הייצור, שבאמצעותו יוחלף ה-Non-terminal.

על מנת להחליט על איזה Non-terminal יוחלף בכלל הייצור, יכולות להיות לנו שתי אפשרויות:

Left-most Derivation

אפשרות זו קובעת כי תמיד ה-Non-terminal השמאלי ביותר הוא זה שיוחלף.

Right-most Derivation

אפשרות זו קובעת כי תמיד ה-Non-terminal הימני ביותר הוא זה שיוחלף.

דוגמא

נתון ה-Grammar הבא:

$E \rightarrow E + E$
$E \rightarrow E * E$
$E \rightarrow id$

עבור מחרוזת הקלט " $id + id * id$ " כך יראו שני סוגי ה-Derivation:

Left-most derivation

$E \rightarrow E * E$
$E \rightarrow E + E * E$
$E \rightarrow id + E * E$
$E \rightarrow id + id * E$
$E \rightarrow id + id * id$

Right-most derivation

$E \rightarrow E + E$
$E \rightarrow E + E * E$
$E \rightarrow E + E * id$
$E \rightarrow E + id * id$
$E \rightarrow id + id * id$

Left Factoring

אם יותר מ – Production rule אחד מתחיל באותה קידומת, אז ה – Parser לא יכול לבצע הכרעה באיזה מהחוקים הוא צריך לבחור בשביל לנתח את הקלט הנוכחי.

דוגמא

אם כלל ייצור מסוים נראה כך:

$$A \Rightarrow \alpha\beta \mid \alpha\gamma \mid \dots$$

המנתח לא יודע להחליט אחרי איזה חוק לעקוב, כיוון ששני החוקים מתחילים באותו Terminal (או Non-terminal).

על מנת להסיר בעיה זאת משתמשים בטכניקה שנקראת Left factoring.

Left factoring ממירה את ה – Grammar כך שלא יהיו חוסר הוודאויות האלו. היא עובדת כך שעבור כל קידומת שמשומשת יותר מפעם אחת יוצרים כלל חדש וההמשך של הכלל הישן משורשר לכלל החדש.

דוגמא

הכלל הקודם יוכל כעת להיראות כך:

$$\begin{aligned} A &\Rightarrow \alpha A' \\ A' &\Rightarrow \beta \mid \gamma \mid \dots \end{aligned}$$

עכשיו למנתח יש רק כלל אחד עבור הקידומת המסוימת הזאת, מה שמקל עליו לקבל החלטות.

Parsing Algorithms

על מנת ליצור Parse Tree עליו יתבסס תהליך הקומפילציה, ישנם כמה אלגוריתמים הנקראים Parsing Algorithms. אלגוריתמים אלה מתחלקים לשני סוגים עיקריים.

1. Top Down Parsing (TDP)

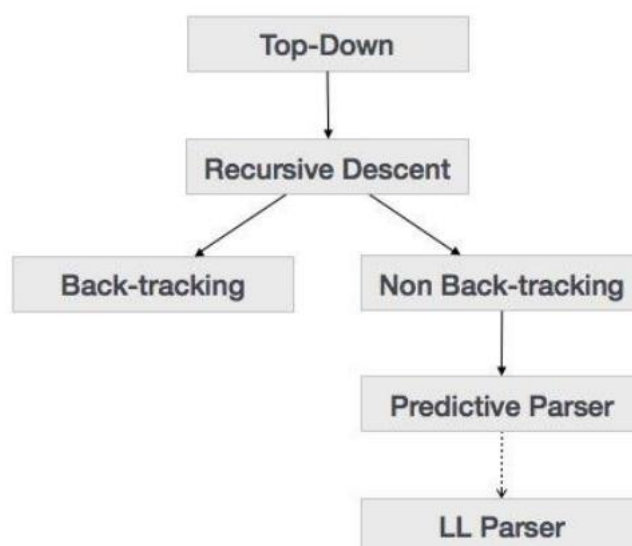
2. Bottom Up Parsing (BUP)

שפות תכנות הן בדרך כלל Context-free languages. נהוג לפרש CFL באמצעות מכונות מצבים, ובאופן יותר ספציפי מכונות מצבים המשתמשות במחסנית (Pushdown machines). לכן האלגוריתמים שזכרנו אציג ישתמשו באוטומט מחסנית לרוב, על מנת לבצע את פעולת ה-Parsing.

Top Down Parsing (TDP)

טכניקה בה עוברים מהחלקים העליונים לחלקים התחתונים של העץ התחבירי, על ידי שימוש בכללי השכתוב של Grammar השפה. עוברים מה-Grammar לקלט.

דיאגרמה המתארת מספר סוגים של Top Down Parsing:



נעת אציג ואסביר על כמה אלגוריתמים שמשתמשים בגישה של Top Down.

Definite Clause Grammar Parsers

Definite Clause Grammar (DCG) הוא דרך להביע תחביר של שפה, בין אם שפה טבעית או פורמלית. DCGs מזוהים בדרך כלל עם Prolog, שפת תכנות לוגית שבניגוד לשפות תכנות רבות אחרות, מיועדת בעיקר כשפת תכנות הצהרתית, כך שההיגיון של התוכנית מתבטא במונחים של יחסים, המיוצגים כעובדות וכללים. ביצוע "חישוב" בה מתבצע על ידי הפעלת שאילתה על היחסים הללו.

```

sentence --> noun_phrase, verb_phrase.
noun_phrase --> det, noun.
verb_phrase --> verb, noun_phrase.
det --> [the].
det --> [a].
noun --> [cat].
noun --> [bat].
verb --> [eats].
  
```

דוגמא ל-DCG ב-Prolog ←

Recursive Decent Parsing

צורה נפוצה של TDP. בשיטה זו, כיוון שהיא שיטה שמתבססת על הגישה של Top Down, עץ הניתוח נוצר מלמעלה למטה, והקלט נקרא משמאל לימין. שיטה זו משתמשת בפונקציות עבור כל Terminal ו- Non-terminal שנמצא ב-Grammar השפה. Recursive descent parser יוצר את עץ הניתוח תוך מעבר רקורסיבי על הקלט, מה שיכול לגרום לו לסבול מ- Back tracking. (האם יהיה או לא יהיה Back tracking תלוי ב-Grammar השפה, אם ה-Grammar הוא Left factored, הוא ימנע מ- Back tracking).

בגלל ה- Back tracking יעילותו של האלגוריתם יכולה להיות אף אקספוננציאלית, כלומר $O(2^n)$.

גרסה של Recursive decent parsing שלא משתמשת ב- Back tracking נקראת Predictive parsing.

Back tracking


כאשר ה- Parser משתמש בשיטה של Recursive decent parsing (וה-Grammar הוא לא Left factored), ייוצרו מצבים במהלך הניתוח של הקלט בהם המנתח יגיע למבוי סתום, וזאת כנראה בגלל שעשה בחירה לא נכונה של כלל מסוים בדרך. לכן, המנתח חוזר חזרה למקום האחרון בו ביצע הכרעה, ושם בוחר באופציה האחרת. החזרה הזאת למקום האחרון בו ביצע הכרעה, על מנת לבצע הכרעה שונה, נקראת Back-tracking. רק כאשר ניסה את כל האפשרויות ולא הצליח להתאים את הקלט לכללי השפה, ניתן להבין שהקלט הוא לא תקין מבחינת השפה.

דוגמא

נתון ה-Grammar הבא:

$S \rightarrow rXd \mid rZd$ $X \rightarrow oa \mid ea$ $Z \rightarrow ai$
--

עבור מחרוזת הקלט "read" כך יראה תהליך הניתוח:



Predictive parsing


Predictive Parser הוא Recursive descent parser אשר יש לו את היכולת לחזות באיזה Production הוא צריך להשתמש בשביל להחליף את הקלט. עקב כך הוא לא סובל מ - Back tracking.

בשביל להשיג יכולת חיזוי זו, ה - Predictive parser "מציץ" לסמלים הבאים בקלט. בשביל שהוא יהיה ללא Back tracking - ה Predictive parser מגביל את ה - Grammar כך שהוא יכול להיות רק מתת-קבוצה של CFGs הנקראת LL(k) Grammars.

Predictive parser משתמש במחסנית (Stack) ובטבלת ניתוח (Parsing table) בשביל לנתח את הקלט ולייצר את עץ הניתוח. הוא פונה ומשתמש בטבלת הניתוח בשביל לקבל החלטה עבור כל צמד של קלט ואיבר במחסנית.

בניגוד ל - Recursive descent parsing שם עבור קלט מסוים יכולים להיות מספר כללים, ב - Predictive parsing יש לכל היותר כלל אחד עבור כל קלט מסוים. כך שבמקרים בהם אין אף כלל שתואם את הקלט, תהליך הניתוח נכשל.

דיאגרמה הממחישה את עבודתו של ה - Predictive parser




LL parser

LL parser מקבל LL grammars. כפי שצייתי לעיל, LL grammars הם תת-קבוצה של Context free grammars.

ניתן ליישם LL parsing באמצעות שני האלגוריתמים שהצגתי קודם, כלומר, Predictive או Recursive descent (באמצעות עזרה של טבלה).

LL parser נכתב גם כ- $LL(k)$, כך שה- L הראשונה מייצגת שהקלט נקרא משמאל לימין, ה- L השנייה מייצגת left-most derivation, ו- k מייצג את מספר הסמלים עליהם "מציצים" קדימה (Look ahead).



Early parser

Early parser, נקרא אחר שמו של מי שהמציא אותו, Jay Early, הוא Parsing algorithm המשתמש בטכניקה של dynamic programming על מנת לנתח את מחרוזת הקלט.

האלגוריתמים הקודמים שתיארתי, לדוגמא Recursive descent, מבוססים על חיפוש רקורסיבי של מבנים תחביריים אפשריים אשר יקבלו את מחרוזת הקלט. שיטה זו של חיפוש יכולה לגרום לכך שחלקים מהמבנה התחבירי הכללי אשר מקבלים חלק מסוים ממחרוזת, מיוצרים שוב ושוב. החזרה הזאת על פתרונות חלקיים בתוך תהליך המבנה התחבירי הכולל, היא התוצאה של ה- Back tracking הדרוש בשיטת חיפוש זאת, מה שיכול להוביל לזמן ביצוע אקספוננציאלי של האלגוריתם. Dynamic programming נותן חלופה יעילה יותר בה החלקים שכבר יוצרו יישמרו לצורך שימוש חוזר בתהליך השלם של הניתוח. כך לא יהיה צורך לחזור על אותם חישובים שוב ושוב, מה שמייעל את האלגוריתם.

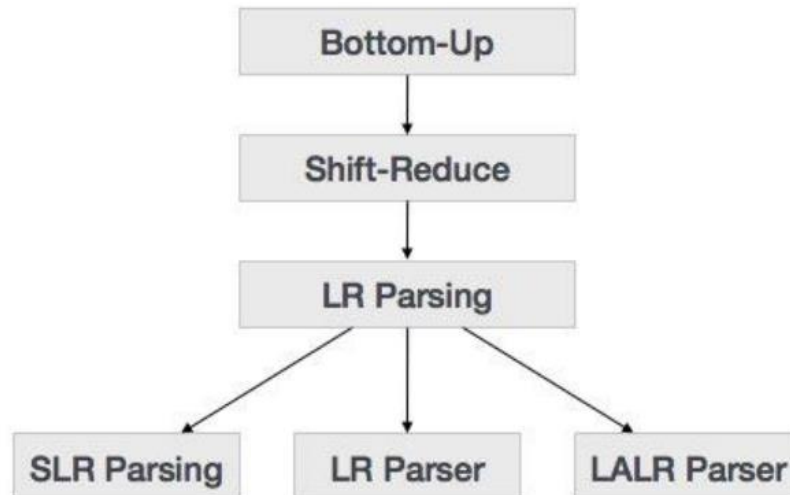
שמירה על פתרונות חלקיים אלו מתבצעת באמצעות מבנה נתונים הנקרא טבלה, *chart*. לכן גרסאות שונות של ה- Early parser נקראות גם *chart parsing*.

יעילות האלגוריתם היא $O(n^3)$

Bottom Up Parsing (BUP)

טכניקה בה עוברים מהחלקים התחתונים לחלקים העליונים של העץ התחבירי, על ידי שימוש בכללי השכתוב של Grammar השפה. עוברים מהקלט אל ה - Grammar.


דיאגרמה המתארת מספר סוגים של Bottom Up Parsing:



כעת אציג ואסביר על כמה אלגוריתמים שמשתמשים בגישה של Bottom Up.

Shift Reduce

Shift Reduce הוא התהליך של הפחתת מחרוזת הקלט ל - Starting non-terminal של ה - Grammar.



שיטה זו משתמשת בשני שלבים הייחודיים ל - Bottom up parsing. שלבים אלו נקראים Shift step ו - Reduce step.

Shift step

שלב זה מבצע מעבר לסמל, Symbol, הבא שמגיע מהקלט, והוא נקרא גם Shifted symbol. סמל זה נדחף (PUSH) למחסנית. ה - Shifted symbol מטופל כצומת אחת של עץ הניתוח.

Reduce step

כאשר המנתח מוצא כלל ייצור שלם, כלומר הסמלים שעל המחסנית תואמים לאחד מה - RHS (Right Hand side) של כללי הייצור של ה - Grammar, ומחליף אותו ב - Non-terminal שנמצא ב - LHS של אותו כלל ייצור, שלב זה נקרא Reduce step. שלב זה בעצם עושה POP למחסנית עבור כל הסמלים שתואמים ל - RHS שמצא, ודוחף למחסנית את ה - LHS התואם.

יעילות האלגוריתם היא $O(n)$

דוגמא

נתון ה – Grammar הבא:

 $S \rightarrow S+S$ $S \rightarrow S-S$ $S \rightarrow (S)$ $S \rightarrow a$ עבור מחרוזת הקלט $a1-(a2+a3)$ כך יראה תהליך הניתוח:

Stack contents	Input string	Actions
\$	$a1-(a2+a3)\$$	shift $a1$
$\$a1$	$-(a2+a3)\$$	reduce by $S \rightarrow a$
$\$S$	$-(a2+a3)\$$	shift $-$
$\$S-$	$(a2+a3)\$$	shift $($
$\$S-($	$a2+a3)\$$	shift $a2$
$\$S-(a2$	$+a3)\$$	reduce by $S \rightarrow a$
$\$S-(S$	$+a3)\$$	shift $+$
$\$S-(S+$	$a3)\$$	shift $a3$
$\$S-(S+a3$	$)\$$	reduce by $S \rightarrow a$
$\$S-(S+S$	$)\$$	shift $)$
$\$S-(S+S)$	$\$$	reduce by $S \rightarrow S+S$
$\$S-(S)$	$\$$	reduce by $S \rightarrow (S)$
$\$S-S$	$\$$	reduce by $S \rightarrow S-S$
$\$S$	$\$$	Accept

LR Parser

LR Parser הוא Parser מסוג Bottom up, אשר מנתח שפות חופשיות הקשר דטרמיניסטיות בזמן לינארי. לרוב משתמש בשיטה של Shift Reduce. LR Parser ידוע גם כ- LR(k) Parser, כך שבדומה ל- LL(k) Parser, ה- L מסמנת קריאה של הקלט משמאל לימין (Left to Right), ה- R מסמנת Right most derivation, וה- k מסמן את מספר הסמלים שה- Parser "מציץ" עליהם קדימה (Look ahead).

ווריאציות שונות של LR Parser הן:

- Look Ahead LR – LALR
- Simple LR – SLR
- Canonical LR – CLR

יעילות האלגוריתם היא $O(n)$

Precedence Parser

בשמו המלא, Operator-Precedence Parser, הוא Parser פשוט המשתמש בשיטה של Shift Reduce, ומסוגל לנתח תת-קבוצה של LR(1) Grammars. ה- Precedence Parser משתמש ב- Precedence (קדימות) של האופרטורים בביטוי מסוים על מנת להחליט איך לנתח אותו.

דוגמא

כפל '*' קודם לחיבור '+', לכן עבור הביטוי $1 + 2 * 3$, האלגוריתם ייחשב ראשית את הערך של $2 * 3$, ורק אז יתווסף 1. כך התוצאה תהיה 7 כמו שהיא צריכה להיות, ולא 9 אם קודם היינו עושים $1 + 2$, ורק אז מכפילים ב-3.

CYK Parser

Tadao, Daniel Younger, John Cocke, נקרא כך אחר שם של המגלים שלו, Cocke–Younger–Kasami algorithm, אלגוריתם זה הוא אלגוריתם מסוג Bottom up והוא משתמש ב – Dynamic programming.

דוגמא

עבור המשפט 'abac' w , הוא יבדוק אם ניתן לייצר:

1. a, b, c
2. ab, ba, ac
3. aba, bac
4. abac

כל בדיקה תתבצע בתקף על הבדיקה הקודמת.

האלגוריתם עושה זאת על ידי יצירת טבלה בגודל $N * N$, כאשר N הוא כמות המילים (אסימונים) במשפט, ומתבסס על התוצאה של השורה הקודמת.

דוגמא לתהליך ניתוח של CYK Parser:

5 letters	C,S,A				
4 letters	-	A,S,C			
3 letters	-	B	B		
2 letters	A,S	B	S,C	A,S	
1 letter	B	A,C	A,C	B	A,C
	b	a	a	b	a

→ AB | BC
 → BA | a
 → CC | b
 → AB | a

1. ba, aa, ab, ba
2. baa (b U aa | ba U a), aab (a U ab | aa U b), aba (a U ba | ab U a)
3. baab (baa U b | b U aab | ba U ab), aaba (aab U a | a U aba | aa U ba)
4. baaba (baa U ba | ba U aba | b U aaba)

יעילות האלגוריתם היא $O(n^3)$

Recursive Ascent Parser

Recursive ascent parser היא טכניקה ליישום LALR Parser (Look Ahead LR Parser) שמשתמשת בפונקציות רקורסיביות, מאשר בטבלאות.

הוא עובד כך שכל פונקציה של ה – Parser מייצגת מצב מסוים אחד במכונת המצבים. בתוך כל פונקציה מתקבלת ההחלטה על איזה פעולה לעשות בהתאם ל – Token הנוכחי. ברגע שה – Token זוהה, הפעולה שתילקח מתבססת על המצב הנוכחי. יש שתי פעולות יסודיות שיכולות להילקח, Shift – ו Reduce.

אסטרטגיה

בפרק זה אציג את האסטרטגיה והגישה לפתרון הבעיה האלגוריתמית הנקראת Compiler.

אייצג את ה – Compiler באמצעות מכונת מצבים. על מנת לעשות זאת ועל מנת לתרגם את קוד המקור, תוך שאיפה ליעילות זמן ריצה לינארית, אשתמש במבנה הנתונים גרף שייצג את מכונת המצבים של ה - Compiler.

כעת אציג כיצד אסטרטגיה זו באה לידי ביטוי בשלבים השונים של תהליך הקומפילציה.

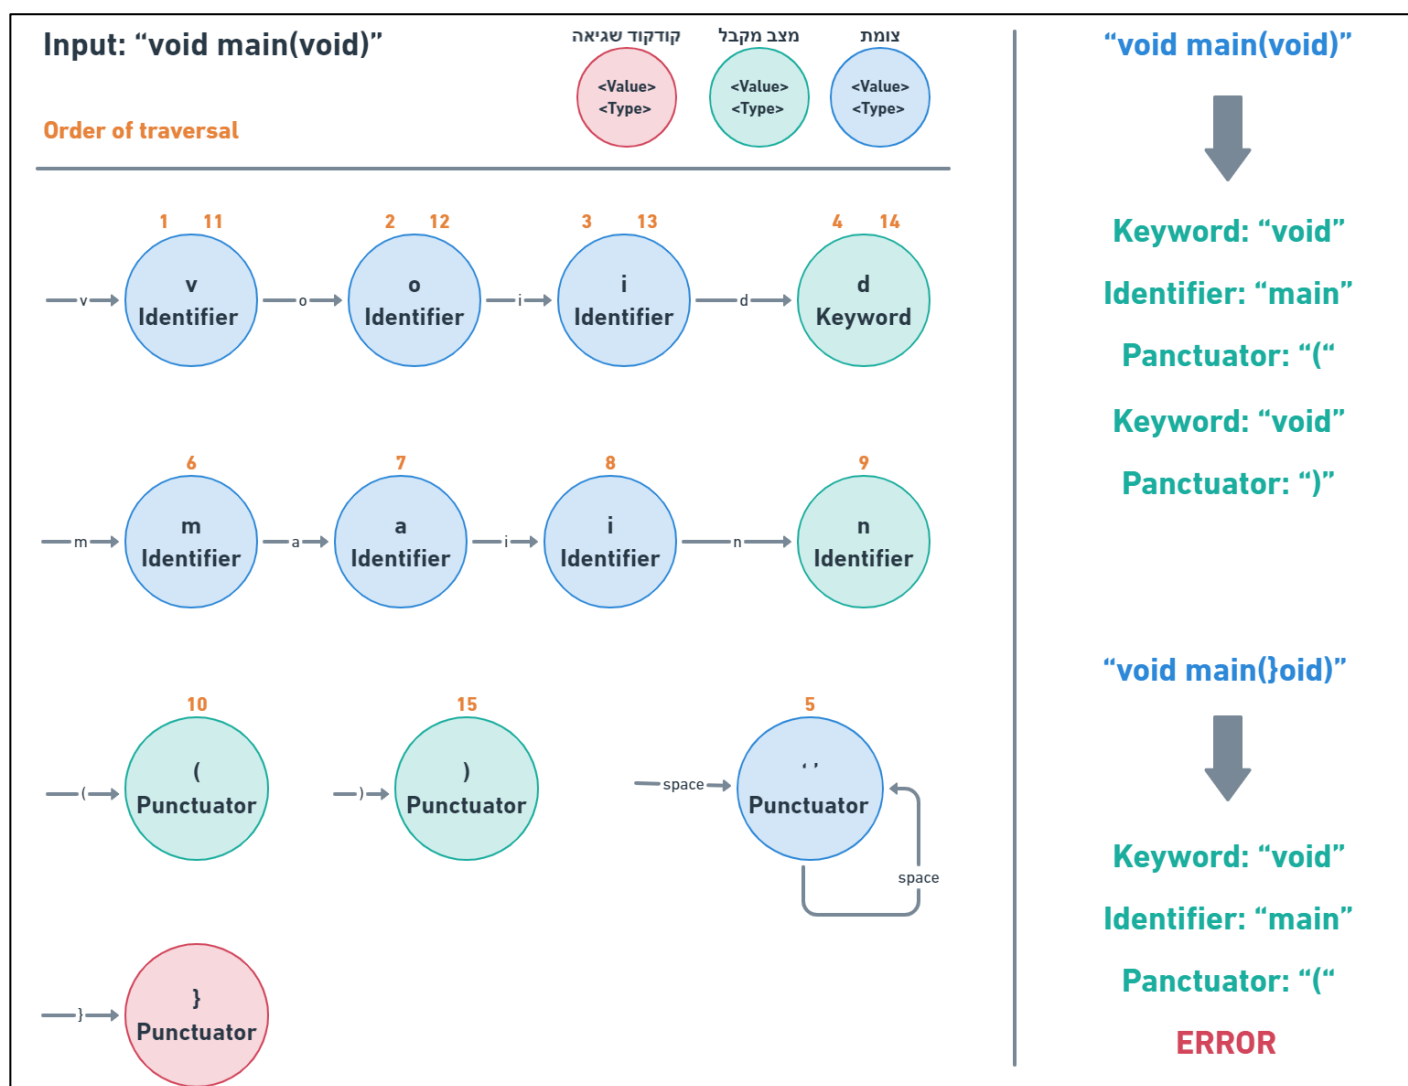
ניתוח מילוני - Lexical Analysis

שוב, מטרתנו לשאוף ליעילות זמן ריצה לינארית. עקב כך אנו לא רוצים להתייחס לקוד המקור אותו אנחנו מתרגמים כטקסט. לכן אנו מתרגמים את קוד המקור לאסימונים בעלי משמעות בקוד, כפי שמתואר בחלק של הסקירה התיאורטית.

המסלול שיייוצר יתבסס על התווים מקוד המקור. המסלול יסתיים כאשר נגיע לקודקוד שהוא עלה, אשר יחזיר סוג אסימון (Identifier, Literal, Operator, Punctuator, Keyword) ששמור אצלו. במקרה וקוד המקור יחיל רצף תווים לא חוקי, המסלול יוביל לקודקוד שגיאה.

דוגמא לתהליך הניתוח המילוני

דוגמא לחילוק מחרוזת הקלט "void main(void)" לאסימונים בשפת C על ידי שימוש באוטומט סופי



מטריצת הסמיכויות

דוגמא עבור מטריצת הסמיכויות של הגרף המייצג את מכונת המצבים של המנתח המילוני.

	''	d	i	o	v	0	1)	...
1	9	5	5	5	2				
2	9			3	5	5	5		
3	9	5	4	5	5	5	5		
4	9	7	5			5	5		
5	9	5		5	5	5	5		
6	9					6	6	8	
...									

במטריצה שלהלן כל שורה מייצגת קודקוד. כל עמודה מייצגת שכנות של קודקוד. השכנות מסודרת לפי סוגי התווים. עבור מצב מסוים ותו נוכחי מקוד המקור, נדע לאיזה מצב אנחנו צריכים לעבור. תא ריק מציין שאין שכנות בין המצב הנוכחי ובין התו הנוכחי מקוד המקור, כלומר הגענו לעלה וזהו סוף האסימון.

אלגוריתם לזיהוי אסימון על ידי גרף זה

- מעבר על הגרף על פי תווי קוד המקור עד הגעה לעלה (יצירת המסלול תתבסס על פי רצף התווים)
- יצירת אסימון על פי העלה שהגענו אליו

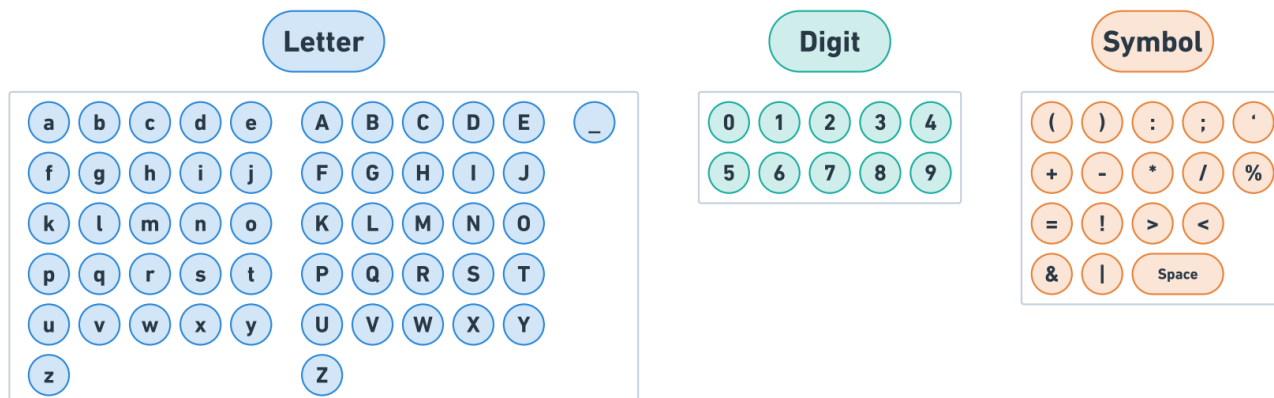
פסאודו קוד

1. **התחל**
2. **אתחל** את גרף האוטומט הסופי של המנתח המילוני
3. **עבור** אל המצב ההתחלתי עבור התו הנוכחי בקוד המקור
4. **כל עוד** לא הגעת לקודקוד שהוא עלה, בצע:
 - 4.1. **עבור** לקודקוד הבא על פי המצב הנוכחי והתו הנוכחי מקוד המקור
 - 4.2. **התקדם** תו אחד בקוד המקור
5. **צור** אסימון על פי העלה שהגעת אליו
6. **חזר** אסימון
7. **סיים**

האוטומט הסופי של המנתח המילוני

האוטומט הסופי של המנתח המילוני, ה-Lexer, עבור השפה שלי, Do.

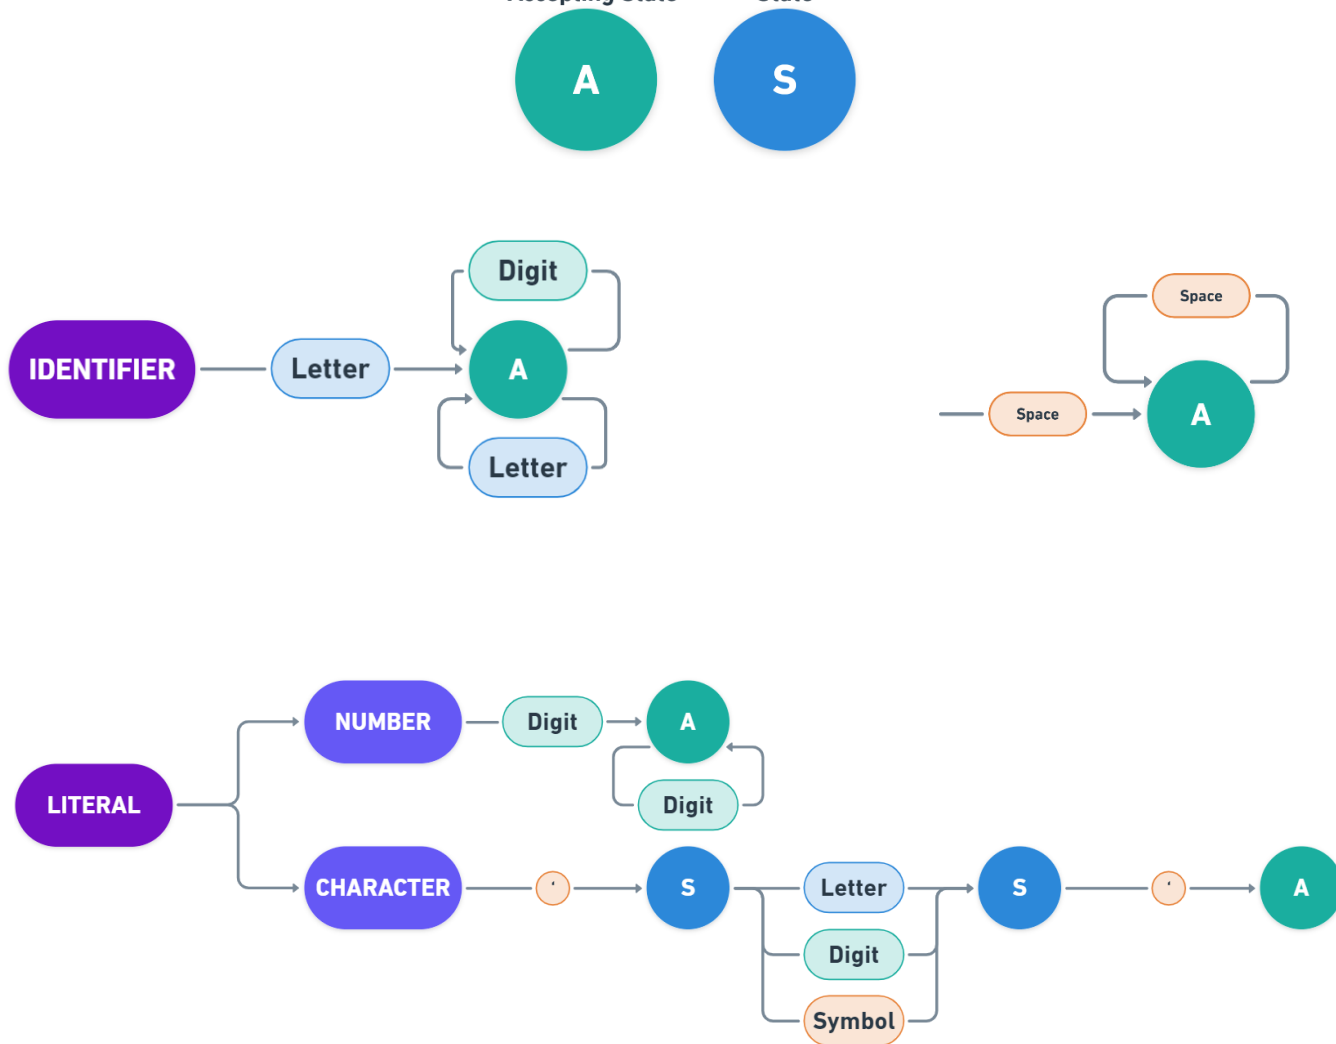
אלפבית

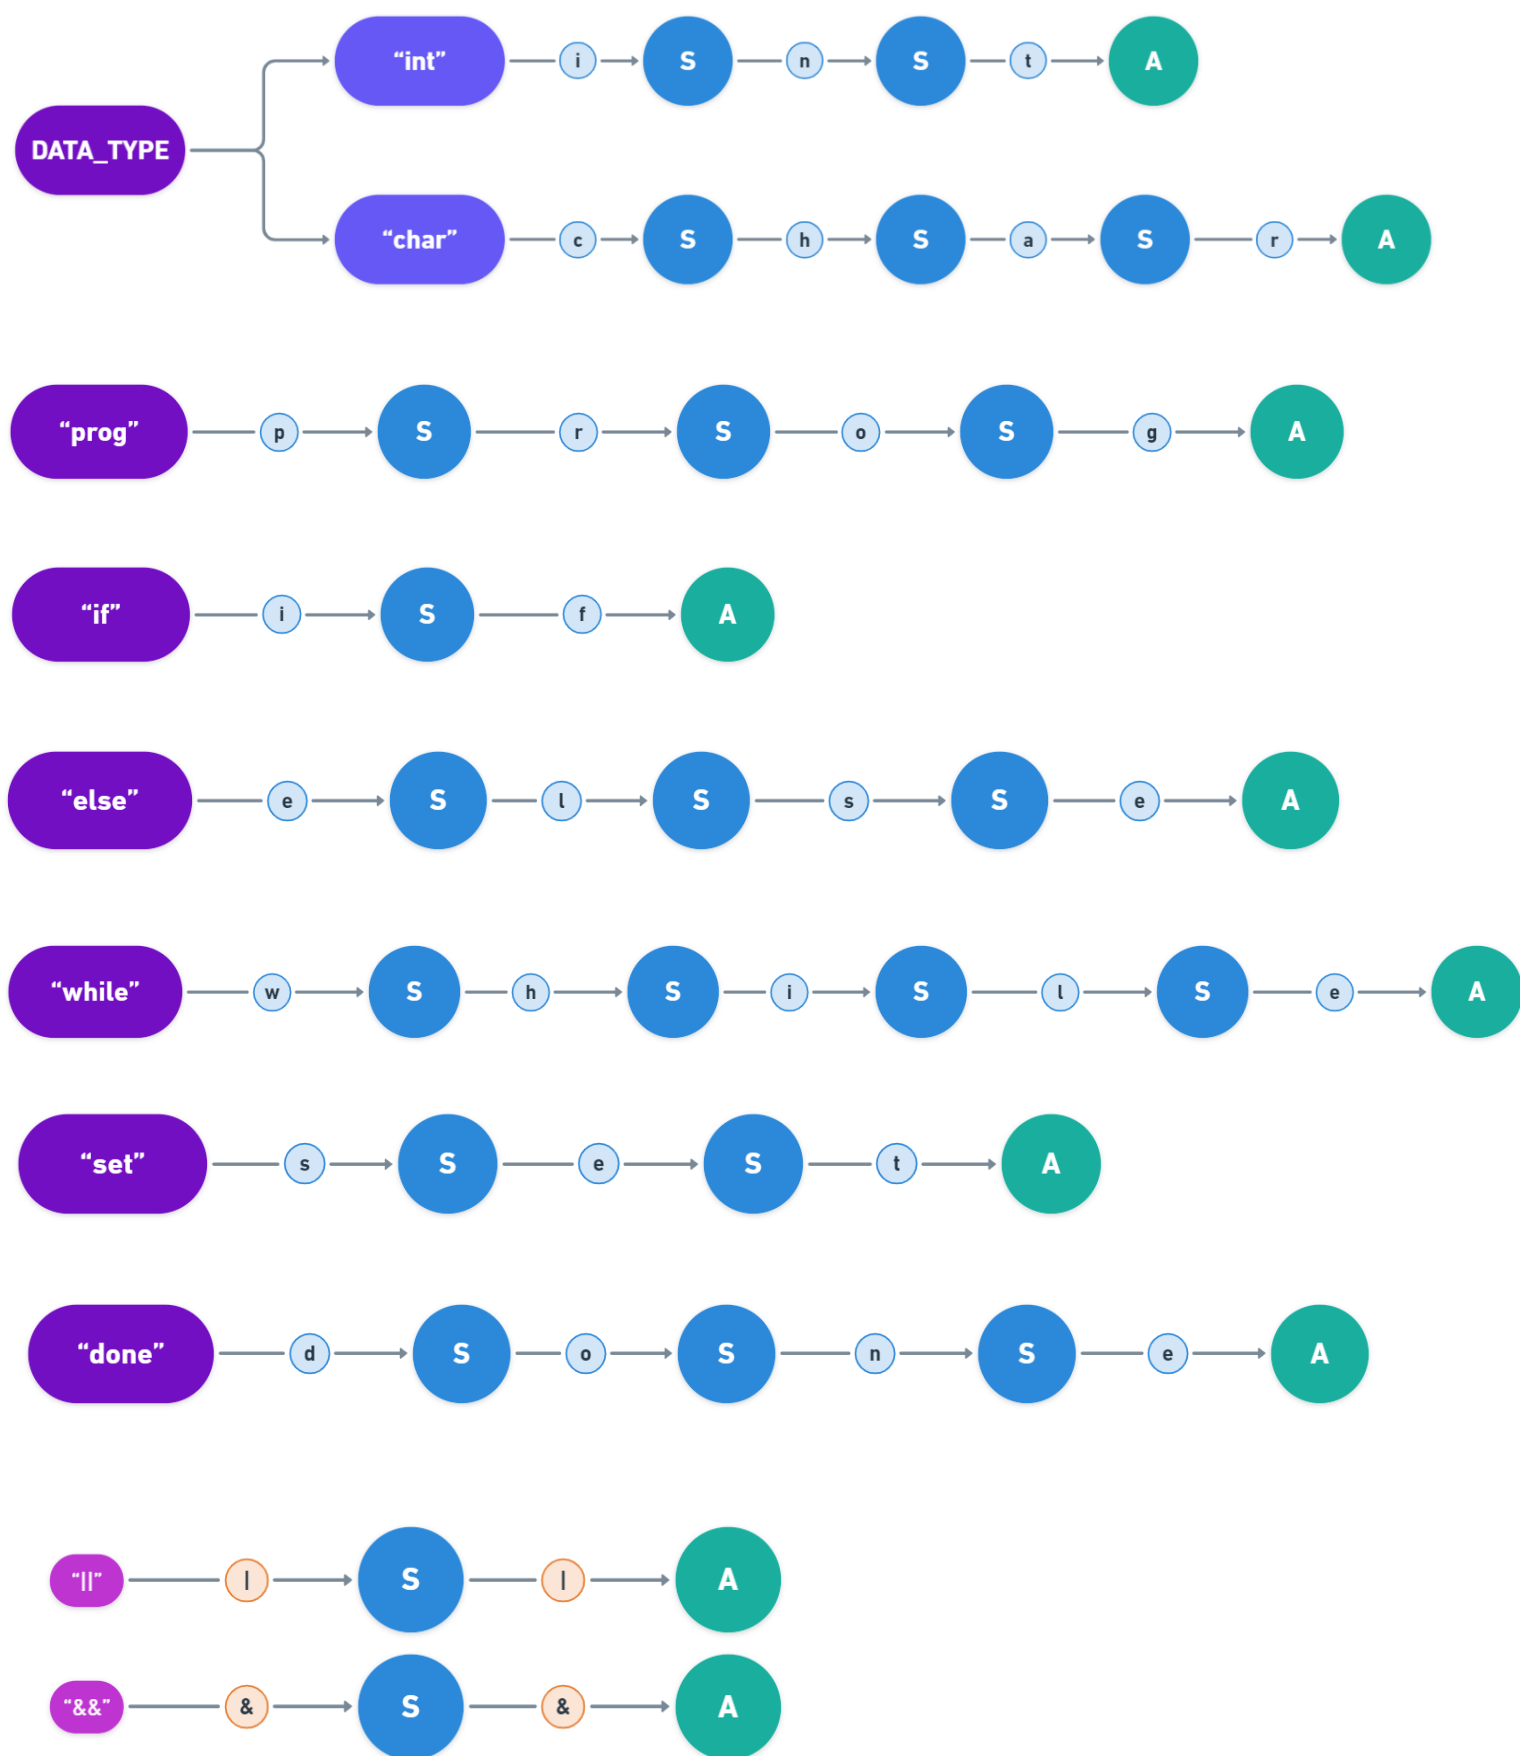


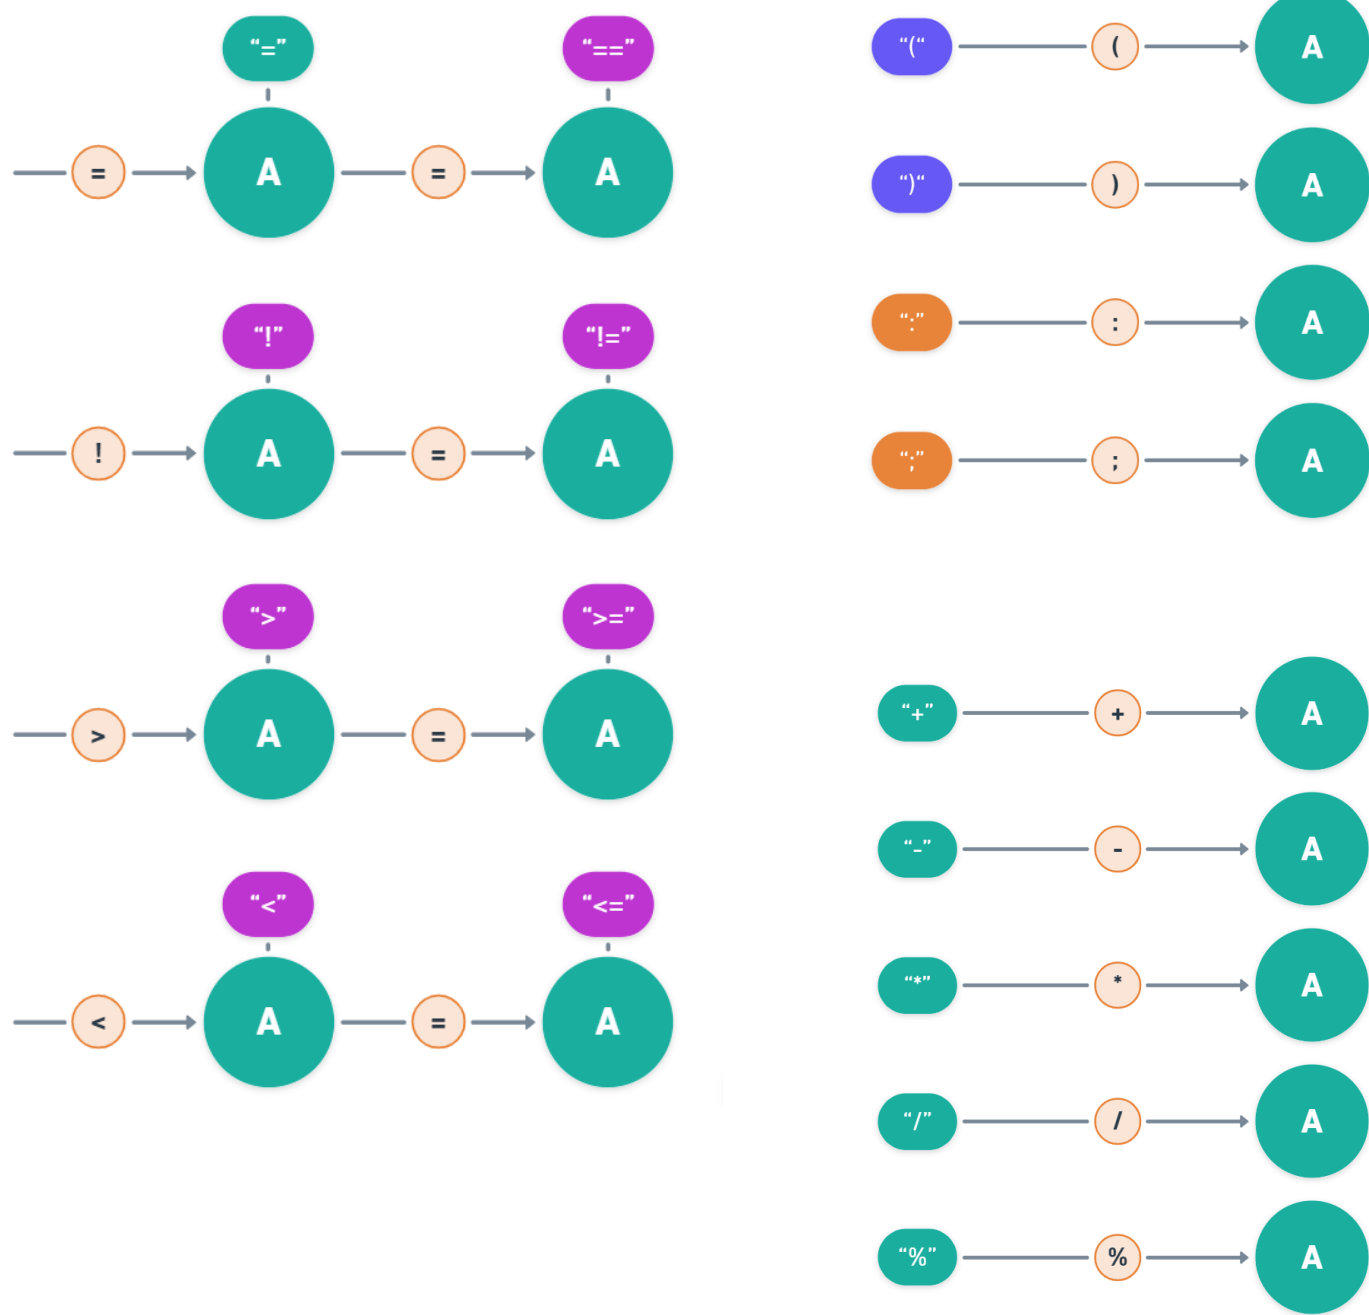
אוטומט

Accepting State

State







ניתוח תחבירי – Syntax Analysis

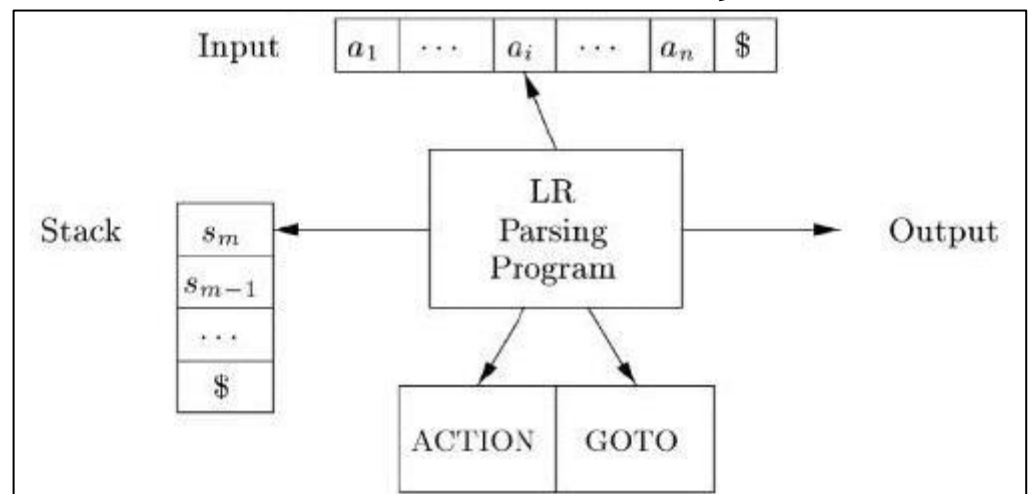
בשלב זה נרצה לבדוק האם רצף האסימונים שקיבלנו מהשלב הקודם הוא רצף אסימונים תקין על פי דקדוק שפת המקור אותה אנחנו מתרגמים, ובנוסף נרצה ליצור עץ ניתוח שייצג את התוכנית התקינה.

בשלב הקודם, שלב הניתוח המילוני, השתמשנו בטבלה עבור מימוש הגרף שמייצג את האוטומט הסופי של המנתח המילוני, בה עבור כל מצב ותו נוכחי ידענו לאיזה מצב עלינו לעבור.

שלב הניתוח התחבירי מורכב יותר. התחביר של שלב זה הוא תחביר חופשי הקשר (CFG) ולכן אינו יכול להתקבל על ידי אוטומט סופי. על מנת לממשו נשתמש באוטומט מחסנית.

כעת שהבנו זאת, טבלה אחת של מצב ותו נוכחי לא תספיק לנו לביצוע המטלה. אנו עדיין שואפים ליעילות זמן ריצה לינארית ולכן נשתמש באלגוריתם ניתוח מסוג Bottom Up, אלגוריתם ה-Shift-Reduce, ובאופן כללי, LR Parser. לפירוט נוסף ראה פרק [סקירת אלגוריתמים בתחום הבעיה](#).

דיאגרמה המתארת את פעולתו של LR Parser



Action table & Goto table & Stack

כפי שניתן לראות, על מנת לממש את ה- LR Parser נשתמש במחסנית, ובשתי טבלאות שיחד ייקראו Parsing table. שתי הטבלאות הן Action table ו- Goto table.

Action table

מציינת למנתח איזו פעולה - Shift, Reduce, Accept או הודעה על שגיאה, Error - הוא צריך לבצע, בהתאם למצב הנוכחי והאסימון הבא מהקלט.

כל שורה תייצג מצב, וכל עמודה תייצג אסימון (Token / Terminal) שנמצא בשפה. נגיע לתא בטבלה על ידי המצב הנוכחי והאסימון הבא מקוד המקור. כל תא בטבלה יגיד לנו איזו פעולה עלינו לעשות, Shift או Reduce, ולאיזה מצב עלינו לעבור לאחר מכן. תא ריק מציין שהגענו למצב שלא יכול להתקיים על פי תחביר השפה, כלומר שגיאה.

בטבלת ה- Action ישנו רק תא אחד שמציין את פעולת ה- Accept. תא זה הוא התא אליו נגיע לאחר שסיימנו את החוק הראשון בדקדוק במלואו, מה שמציין תוכנית תקינה.

Goto table

מציינת למנתח לאיזה מצב הוא צריך לעבור לאחר ביצוע פעולת ה- Reduce.

בטבלת ה- Goto כל שורה תייצג מצב, וכל עמודה תייצג משתנה (Non-terminal) שנמצא בתחביר השפה. נגיע לתא בטבלה על ידי המצב הנוכחי והמשתנה (Non-terminal) אשר נמצא בראש המחסנית. כל תא בטבלה יגיד לנו לאיזה מצב עלינו לעבור בהתאם למצב הנוכחי ולמשתנה שנמצא בראש המחסנית לאחר ביצוע פעולת ה- Shift או ה- Reduce אשר ה- Action table אמרה לנו לעשות.

דוגמא ל – Action table ו Goto table

State	Action Table						Goto Table		
	id	+	*	()	\$	E	T	F
0	S5			S4			1	2	3
1		S6				ACC			
2		R2	S7		R2	R2			
3		R4	R4		R4	R4			
4	S5			S4			8	2	3
5		R6	R6		R6	R6			
6	S5			S4				9	3
7	S5			S4					10
8		S6			S11				
9		R1	S7		R1	R1			
10		R3	R3		R3	R3			
11		R5	R5		R5	R5			

מחסנית

המחסנית תחזיק בתוכה זוגות של Terminal או Non-terminal ומספר מצב. בראש המחסנית תמיד יימצא מספר המצב הבא אליו צריך לעבור. המחסנית תאוחל עם איבר אחד שהוא מספר המצב הראשון, 0.

עבור כל פעולת Shift נדחוף למחסנית שני איברים: האחד הוא ה – Terminal הנוכחי מקוד המקור, והשני הוא מספר המצב כפי שצוין ב – Action table.

עבור כל פעולת Reduce נוציא מהמחסנית את כמות האיברים שנמצאת ב – RHS של חוק הדקדוק שצוין ליד פעולת ה – Reduce בטבלת ה – Action כפול 2 (משום שעבור כל איבר שנדחף למחסנית אנו גם דוחפים את מספר המצב אליו צריכים לעבור), ונדחוף למחסנית את ה – Non-terminal שנמצא ב – LHS של אותו חוק דקדוק. כעת כל שנותר הוא לדחוף את מספר המצב הבא לראש המחסנית. ניתן לדעת מספר זה על ידי התא בטבלת ה – Goto שנמצא בעמודה של ה – LHS של חלק הדקדוק שכעת דחפנו, ובשורה של מספר המצב שנמצא תחתיו במחסנית.

כך תראה המחסנית בהתחלה

0									
---	--	--	--	--	--	--	--	--	--

לאחר שתי פעולות Shift 3 ל – Terminal שהוא a

0	a	3	a	3					
---	---	---	---	---	--	--	--	--	--

לאחר פעולת Reduce עבור חוק הדקדוק $A \rightarrow aa$

0	A								
---	---	--	--	--	--	--	--	--	--

דחיפת מספר המצב המתאים על פי טבלת ה – Goto במיקום [0, A]

0	A	4							
---	---	---	--	--	--	--	--	--	--

אלגוריתם הניתוח

כעת אציג את הפסאודו קוד עבור אלגוריתם הניתוח בעזרת המחסנית, ה – Action table וה – Goto table.

פסאודו קוד

1. **התחל**
2. **אתחל** את המחסנית ואת הטבלאות Action & Goto
3. **הכנס** למשתנה a את האסימון הראשון מקוד המקור
4. **כל עוד** לא סיימת (מצב מקבל / מצב שגיאה), **בצע**:
 - 4.1. **הכנס** למשתנה s את המצב שנמצא בראש המחסנית
 - 4.2. **אם** $Action[s, a] = Shift\ t$ **בצע**:
 - 4.2.1. **דחוף** את a למחסנית
 - 4.2.2. **דחוף** את t למחסנית
 - 4.2.3. **הכנס** למשתנה a את האסימון הבא מקוד המקור
 - 4.3. **אחרת אם** $Action[s, a] = Reduce\ u$ **בצע**:
 - 4.3.1. **הוצא** $2 * Length(Production\ rule\ u)$ איברים מהמחסנית
 - 4.3.2. **הכנס** למשתנה v את המצב הנמצא כעת בראש המחסנית
 - 4.3.3. **דחוף** למחסנית את A, ה – Non-terminal שנמצא ב – LHS של Production rule u
 - 4.3.4. **דחוף** את $Goto[v, A]$ למחסנית
 - 4.3.5. ******* כן ייכנס החלק בו מכניסים את ה – Production rule u לעץ הניתוח *******
 - 4.4. **אחרת אם** $Action[s, a] = Accept$ **בצע**:
 - 4.4.1. **סיים** את הלולאה וקבל
 - 4.5. **אחרת, בצע**:
 - 4.5.1. **סיים** ודווח על שגיאה
5. **סיים**

מימוש LR Parser

כעת יש לנו את התאוריה והאלגוריתם לניתוח באמצעות המחסנית ושתי הטבלאות. אך על מנת להשתמש בטבלאות אלה נצטרך לבנות אותן קודם. כיצד נבנה שתי טבלאות אלה? נראה כעת.

ניתן לחלק את מימוש ה – LR Parser לשני חלקים על מנת לפשט את ההסבר:

1. יצירה של דיאגרמת המעברים, בעצם האוטומט, הגרף, של תחביר השפה.
2. יצירה של ה – Parsing table, הבנויה משתי טבלאות: Action table ו – Goto table בעזרת דיאגרמת המעברים.

The Dot notation

Notation באמצעות נקודה הנמצאת בין חלקים שונים של Production rule, המציינת כמה מאותו Production rule כבר ראינו. הנקודה, Dot, יכולה להופיע בכל מקום בחלק הימני (RHS) של Production rule.

לדוגמא, חוק הדקדוק $A \rightarrow XYZ$ נותן לנו 4 אופציות:

$A \rightarrow \cdot XYZ$
$A \rightarrow X \cdot YZ$
$A \rightarrow XY \cdot Z$
$A \rightarrow XYZ \cdot$


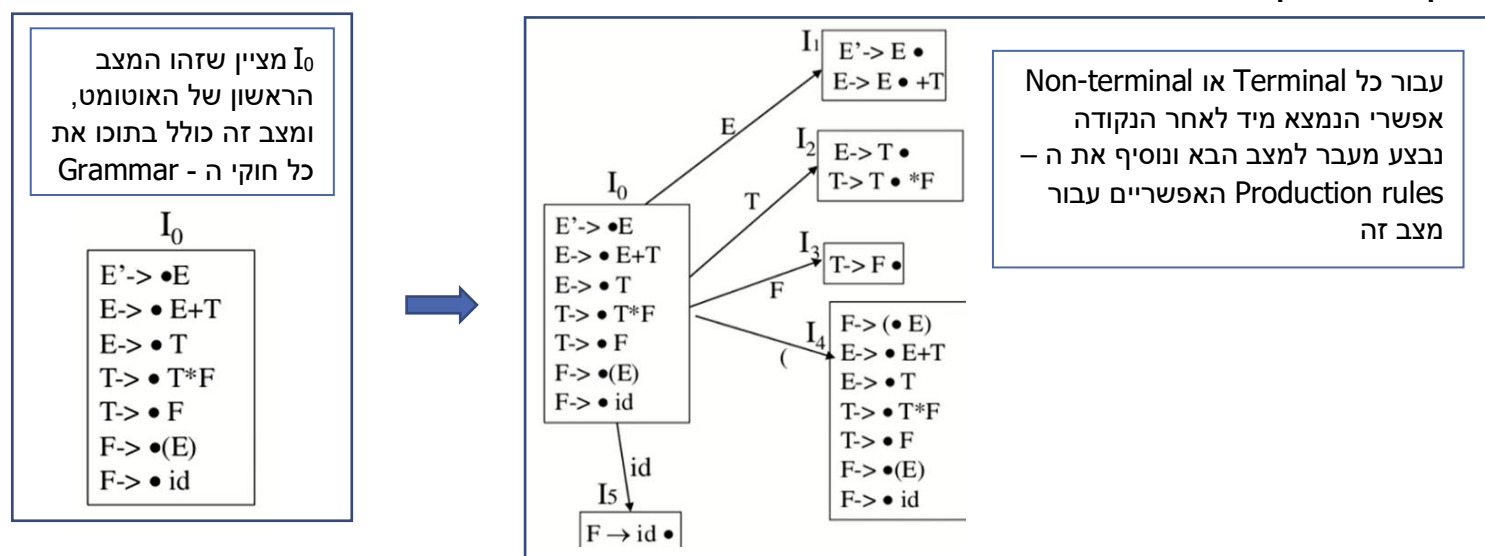
בניית דיאגרמת המעברים

כפי שצינתי לעיל, השלב הראשון במימוש LR Parser הוא יצירה של דיאגרמת המעברים עבור תחביר השפה. כעת אסביר כיצד שלב זה קורה בעזרת שימוש ב – Dot notation.

ניקח את ה - Grammar הבא

$E' \rightarrow \bullet E$
 $E \rightarrow \bullet E + T$
 $E \rightarrow \bullet T$
 $T \rightarrow \bullet T * F$
 $T \rightarrow \bullet F$
 $F \rightarrow \bullet (E)$
 $F \rightarrow \bullet id$

כך יראה תהליך הבנייה של דיאגרמת המעברים עבור Grammar זה



כך מתואר תהליך הבנייה של הדיאגרמה

אנו מתחילים מה – Grammar המקורי, ועבור כל סימן שמופיע מיד אחרי הנקודה אנו עוברים למצב המתאים. חוזרים על פעולה זו עבור כל המצבים החדשים עד שלא מתווספים יותר מצבים חדשים. כך, כאשר יש לנו דיאגרמה זו, אנו יכולים לדעת מהם כל המצבים באוטומט שלנו, איזה חוקים אפשריים בכל מצב, ועבור איזה סמל עוברים לאיזה מצב.

בניית הטבלאות

השלב הקודם נתן לנו את דיאגרמת המעברים, האוטומט, של ה – LR Parser שלנו. כעת נרצה ליצור מדיאגרמה זו את שתי הטבלאות שאיתן בפועל נבצע את תהליך הניתוח התחבירי.

מעבר על קשתות - Shift

בשביל לבנות את שתי הטבלאות תחילה נעבור על כל הקשתות, המעברים, בדיאגרמה מהשלב הקודם. עבור קשת עם משקל שהוא Non-terminal נעדן מעבר זה בטבלת ה – Goto table, עבור קשת עם משקל שהוא Terminal נעדן בטבלת ה – Action פעולת (S) Shift וצמוד אליה מספר המצב אליו צריך לעבור לאחר ביצוע פעולת ה - Shift.

כך יראו הטבלאות לאחר שעברנו על כל הקשתות שבדיאגרמה מהשלב הקודם

State	Action Table						Goto Table		
	id	+	*	()	\$	E	T	F
0	S5			S4			1	2	3
1		S6				ACC			
2			S7						
3									
4	S5			S4			8	2	3
5									
6	S5			S4				9	3
7	S5			S4					10
8		S6			S11				
9			S7						
10									
11									

מעבר על מצבים - Reduce

כעת נעבור על כל המצבים בעלי הנקודה בסוף ה - Production rule בדיאגרמה מהשלב הקודם, המציינים שהגענו לסוף של Production rule ושניתן לבצע Reduce (מסומנים בכחול בדיאגרמה). זאת במטרה לסמן את כל פעולות ה - Reduce בטבלת ה - Action. אך על מנת לעשות זאת נצטרך להכיר עוד שני מושגים נוספים: First set ו - Follow set.

First & Follow sets

חלק חשוב מהתהליך של יצירת ה - Parsing table הוא היצירה של ה - First & Follow sets. אלו יכולים לספק לנו את המיקום המדויק של כל Terminal ב - Derivation. זאת על מנת להקל על קבלת ההחלטה על פעולת ה - Reduce ב - Parsing table.

בקצרה, First set הם כל ה - Terminals שיכולים להופיע ישירות לאחר שעושים Derivation ל - Non-terminal כזה או אחר, ו - Follow set הם כל ה - Terminals שיכולים להופיע מיד לאחר Non-terminal כזה או אחר.

אנו נתמקד ונשתמש בעיקר ב - Follow set. ה - Follow set של Non-terminal, נקרא לו A, יהיה כל ה - Terminals שיכולים להופיע מיד לאחר A בכל ה - Production rule בהם A מופיע. גם אם יש Non-terminals בין לבין, אנו מתעלמים מהם וממשיכים לבצע Derivations עד שנגיע ל - Terminals שיכולים להיות ישר לאחר A.

לדוגמא, כך יראה ה - Follow set עבור ה - Grammar מהשלבים הקודמים

(0) $E' \rightarrow E$
 (1) $E \rightarrow E + T$
 (2) $E \rightarrow T$
 (3) $T \rightarrow T * F$
 (4) $T \rightarrow F$
 (5) $F \rightarrow (E)$
 (6) $F \rightarrow id$

$Follow(E) = \{ \$, +,) \}$
 $Follow(T) = \{ *, +,), \$ \}$
 $Follow(F) = \{ *, +,), \$ \}$

אלגוריתם לחישוב Follow set

- אם A הוא המצב ההתחלתי, אזי $Follow(A) \subseteq \$$
- אם A הוא Non-terminal ויש לו Production כדוגמת $S \rightarrow A$, אזי $Follow(A) \subseteq Follow(S)$
- אם A הוא Non-terminal ויש לו Production כדוגמת $S \rightarrow AB$, אזי $Follow(A) \subseteq First(B)$ למעט ϵ
- אם A הוא Non-terminal ויש לו Production כדוגמת $S \rightarrow ABC$, אזי $Follow(A) \subseteq First(C)$ למעט ϵ

כעת שאנו יודעים לחשב את ה - Follow set, נוכל להמשיך במילוי טבלת ה - Action בפעולות ה - Reduce.

עבור כל מצב בו הנקודה נמצאת בסוף ה - Production rule (מצבים אלו מסומנים בכחול בדיאגרמה מהשלב הקודם), נסמן בכל העמודות שבשורה של המצב הנוכחי שנמצאות ב - Follow set של המצב הנוכחי, Reduce (R) ועל פי איזה כלל עשינו Reduce (בעזרת המספרים שמסומנים בסוגריים ב - Grammar הצבוע בכתום שלעיל).

כפי שמוסבר לעיל, אנו מבצעים את פעולת ה - Reduce המתאימה רק בעמודות הנמצאות ב - Follow set של המצב הנוכחי. כלומר, אנו בעצם "מסתכלים קדימה" אסימון אחד, על מנת לקבוע את הפעולה הנוכחית. הסתכלות קדימה זו הופכת את ה - LR Parser שלנו ל - $SLR(1)$, כלומר אנו מסתכלים קדימה אסימון אחד בכל שלב.

טבלה סופית

כך יראו הטבלאות לאחר סיום שלב זה. אלו הטבלאות הסופיות איתן נבצע את תהליך הניתוח התחבירי

State	Action Table						Goto Table		
	id	+	*	()	\$	E	T	F
0	S5			S4			1	2	3
1		S6				ACC			
2		R2	S7		R2	R2			
3		R4	R4		R4	R4			
4	S5			S4			8	2	3
5		R6	R6		R6	R6			
6	S5			S4				9	3
7	S5			S4					10
8		S6			S11				
9		R1	S7		R1	R1			
10		R3	R3		R3	R3			
11		R5	R5		R5	R5			

דוגמא לניתוח בעזרת ה – Parsing table

עבור $\text{id} * \text{id} \$$ (מציין סוף המחרוזת) כך יראה תהליך הניתוח בעזרת הטבלה שלעיל ואלגוריתם הניתוח שהוצג קודם

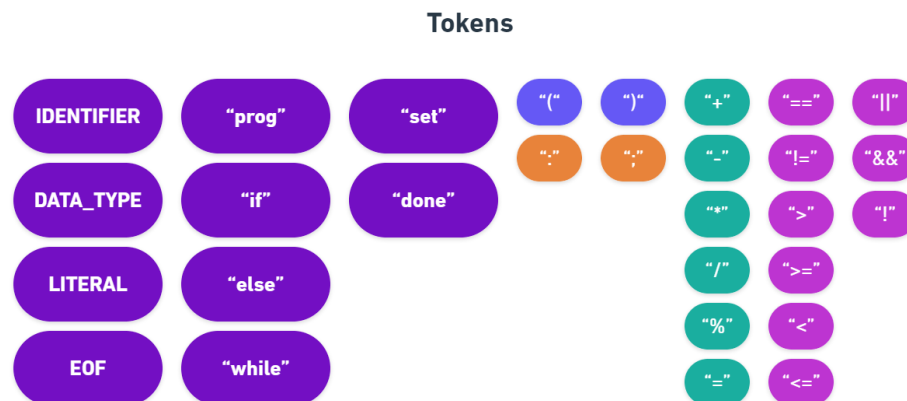
Stack	Input	Action
0	id * id \$	S5
0 id 5	* Id \$	F->id
0 F	* id \$	
0 F 3	* id \$	T->F
0 T 2	* id \$	S7
0 T 2 * 7	id \$	S5
0 T 2 * 7 id 5	\$	
0 T 2 * 7 id 5	\$	F->id
0 T 2 * 7 F 10	\$	T->T*F
0 T 2	\$	E->T
0 E 1	\$	ACC

ניתוח השפה Do

כעת אציג כיצד התאוריה שהצגתי לעיל באה לידי ביטוי בניתוח השפה שלי, Do.

Tokens

אלו הם האסימונים של השפה Do. אלו הם בעצם אבני הבנייה, ה – Terminals, של תחביר השפה. וכפי שצינתי קודם, אלה מגיעים לשלב זה מהשלב הקודם, Lexical analysis.



Grammar

כעת אציג את תחביר השפה Do בשתי תצורות, האחת היא BNF, Notation לכתובה של שפה פורמלית (כפי שצוין בספר [השפה Do](#)), והשנייה היא Railroad Diagram, דיאגרמה ויזואלית לתיאור חוקים של שפה פורמלית. שתי התצורות אמנם נראות שונה, אך זהות לחלוטין במשמעותן.

BNF

```
# PROGRAM
<program> ::= "prog" <IDENTIFIER> ":" <block> ":"

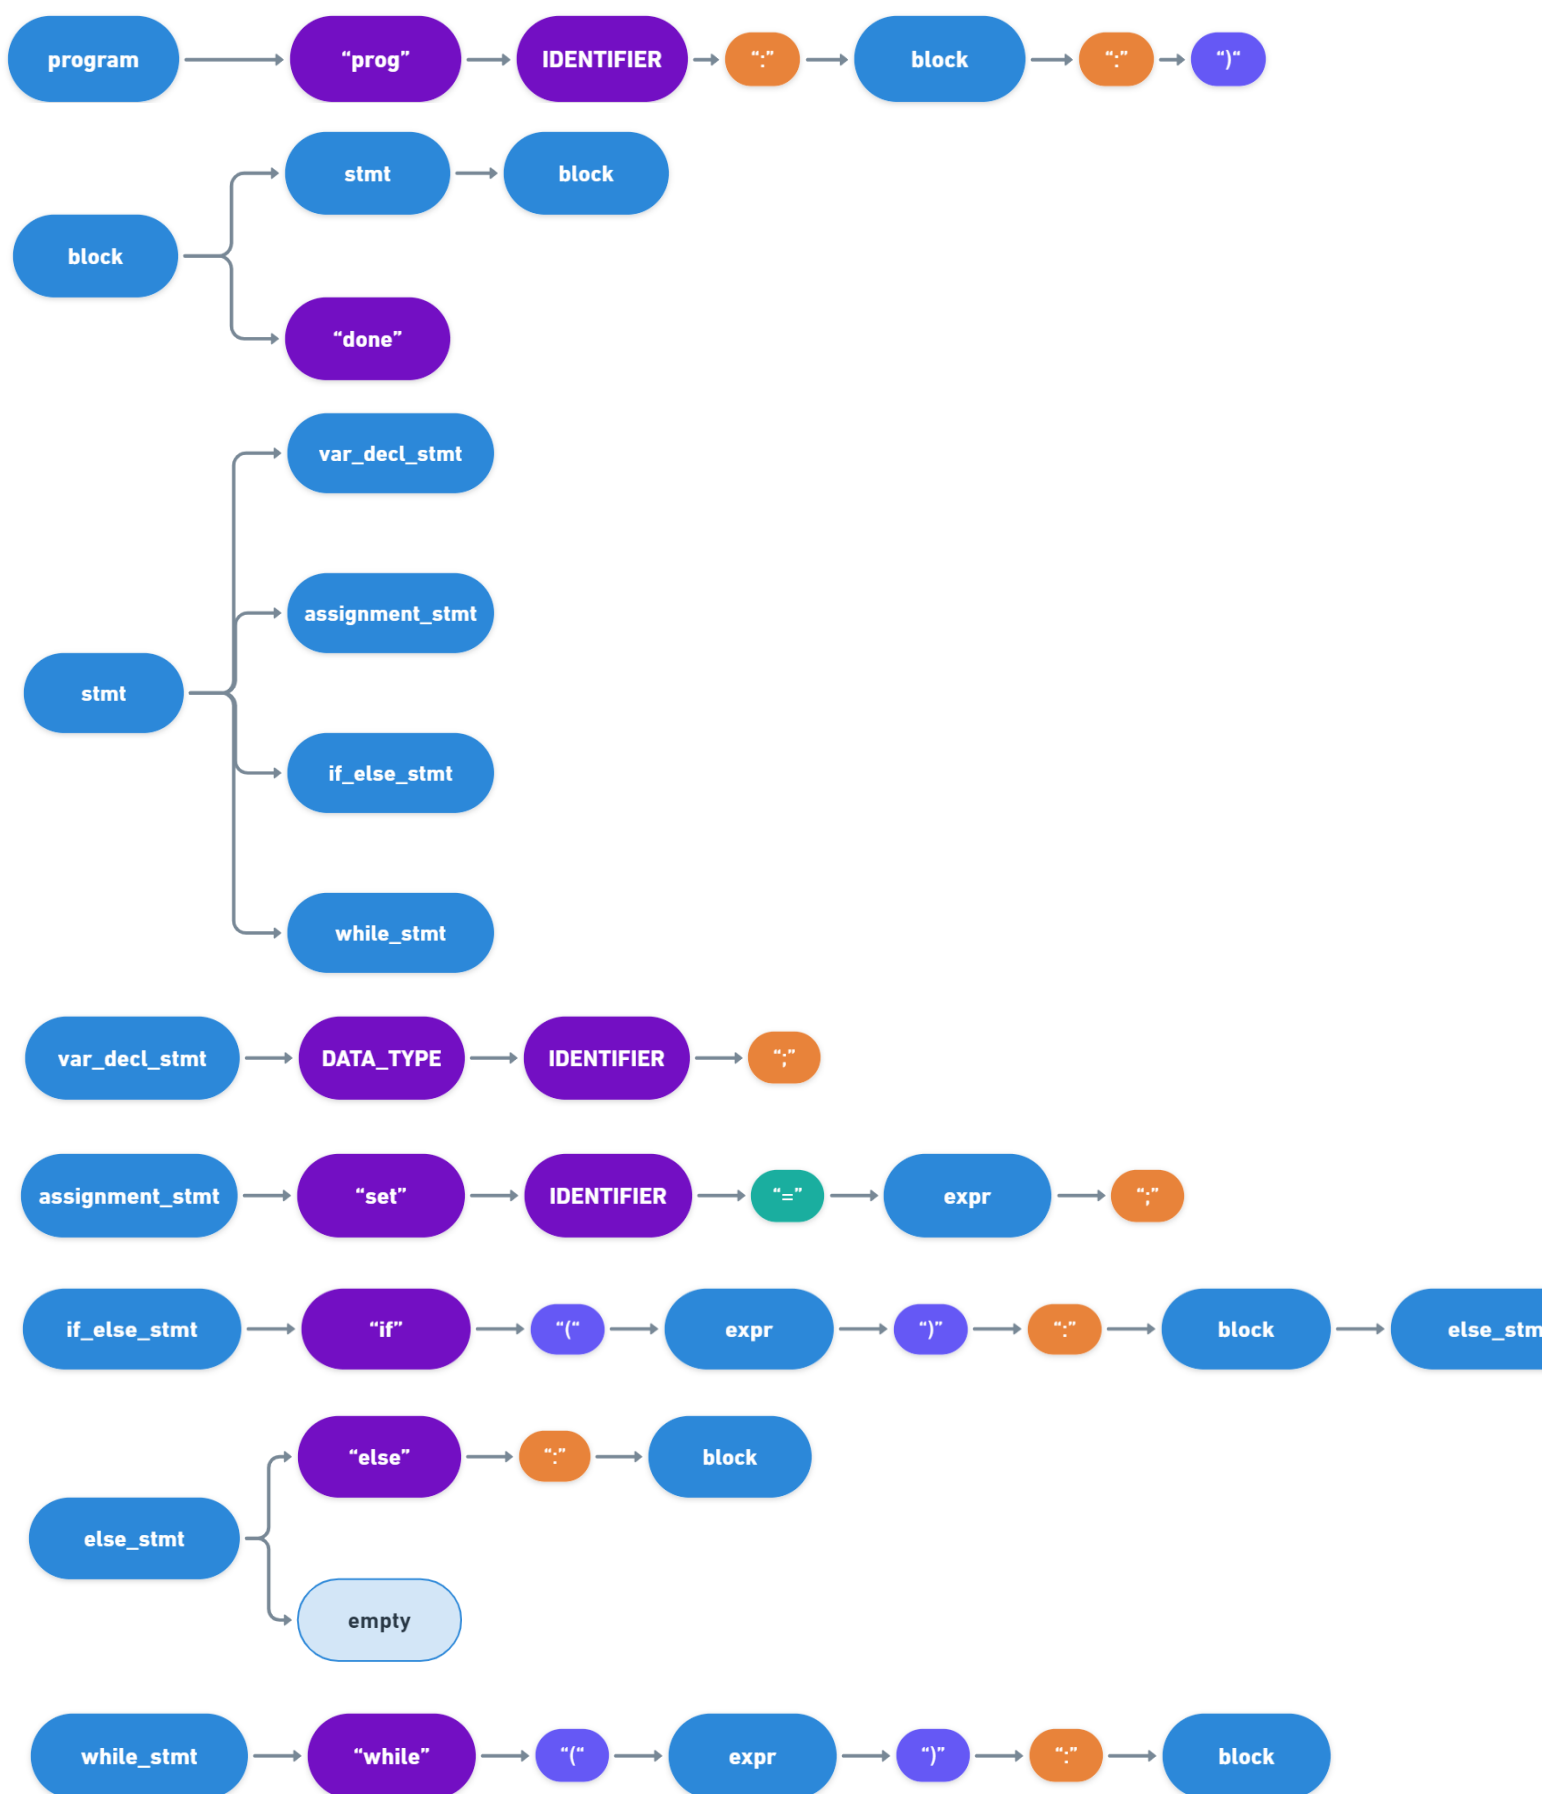
# BLOCK
<block> ::= <stmt> <block> | "done"


# STATEMENTS
<stmt> ::= <var_decl_stmt> | <assignment_stmt> | <if_else_stmt> | <while_stmt>
## variable declaration
<var_decl_stmt> ::= <DATA_TYPE> <IDENTIFIER> ";"
## assignment
<assignment_stmt> ::= "set" <IDENTIFIER> "=" <expr> ";"
## if else
<if_else_stmt> ::= "if" "(" <expr> ")" ":" <block> <else_stmt>
<else_stmt> ::= "else" ":" <block> | <EMPTY>
## while
<while_stmt> ::= "while" "(" <expr> ")" ":" <block>

# EXPRESSIONS
<expr> ::= <term> | <term> <expr_op> <expr>
<term> ::= <factor> | <factor> <term_op> <term>
<factor> ::= <IDENTIFIER> | <LITERAL> | "(" <expr> ")" | "!" <factor> | "-" <factor>

<expr_op> ::= "+" | "-" | "||" | "&&"
<term_op> ::= "*" | "/" | "==" | "!=" | ">" | ">=" | "<" | "<="
```

Railroad Diagram





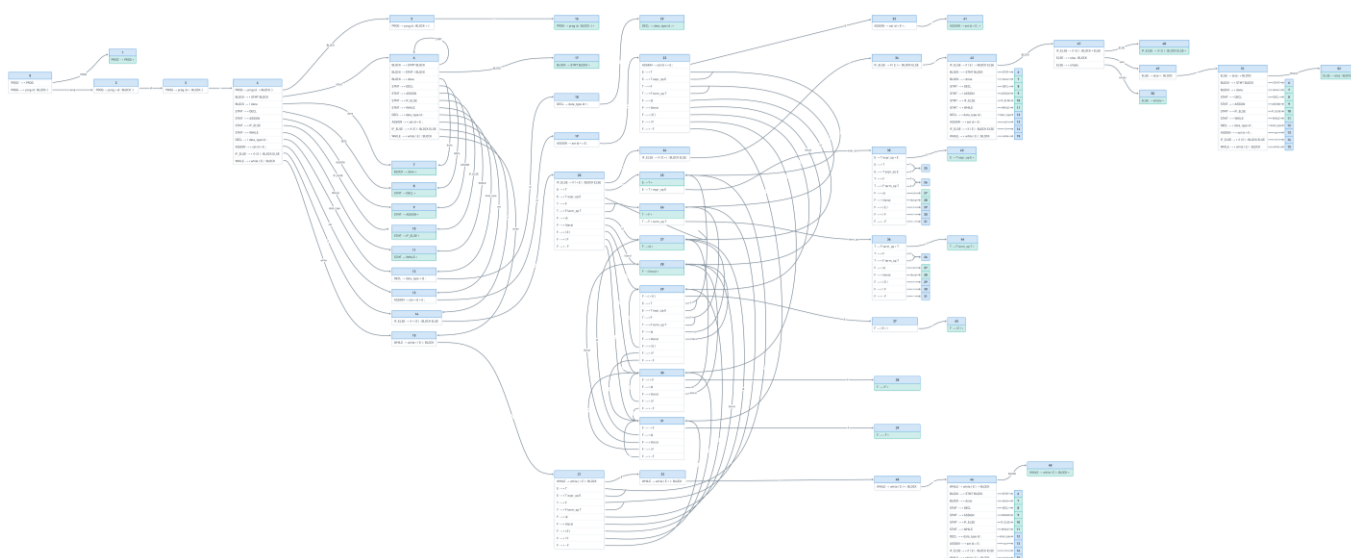
דיאגרמת המעברים עבור Grammar השפה

כך נראית דיאגרמת המעברים, האוטומט, הגרף, עבור Grammar השפה שהצגתי לעיל, כשלב הראשון ליצירת טבלת ה- Action וטבלת ה- Goto בהן המנתח המילוני שלנו ישתמש.

ה- **Grammar** יחד עם מספרי החוקים

	GRAMMAR
1	PROG' → PROG
2	PROG → prog id : BLOCK ;)
3	BLOCK → STMT BLOCK
4	BLOCK → done
5	STMT → DECL
6	STMT → ASSIGN
7	STMT → IF_ELSE
8	STMT → WHILE
9	DECL → data_type id ;
10	ASSIGN → set id = E ;
11	IF_ELSE → if (E) : BLOCK ELSE
12	ELSE → else : BLOCK
13	ELSE → empty
14	WHILE → while (E) : BLOCK
15	E → T
16	E → T expr_op E
17	T → F
18	T → F term_op T
19	F → id
20	F → literal
21	F → (E)
22	F → ! F
23	F → - F

הדיאגרמה



זוהי דיאגרמה ענקית ובתמונה קטנה זו הפרטים הרבים בה לא ברורים. צירפתי תמונה זו רק בשביל לקבל מבט על של הדיאגרמה. קובץ הדיאגרמה יצורף כנספח.

טבלאות Action & Goto עבור Grammar השפה

כעת כשיש בידינו את דיאגרמת המעברים של תחביר השפה, נתרגמה לטבלאות ה – Action & Goto.

ניתוח סמנטי – Semantic Analysis

על מנת לבחון האם רצף האסימונים נכון מבחינה סמנטית, עלינו לוודא זאת:

- בדיקת נכונות סוגי המשתנים
- בדיקת נכונות רצף שימוש במשתנים (הגדרה לפני שימוש)
- בדיקת ייחודיות שמות המשתנים

על מנת לעשות זאת, נוסיף לדקדוק השפה שלנו עוד "תכונות", חוקים, אשר צריך לוודא שמתקיימים עבור רצף אסימונים בשביל לקבוע האם הוא נכון סמנטית.

כגון:

*** דוגמא ***

Code Generation

עבור שלב זה נחזיק פונקציות בסיסיות שיעזרו לנו לתרגם לקוד בשפת אסמבלי:

getreg – מחזיר אוגר פנוי בשלב שצריך לאחסן בו ערך או משתנה.

*** פירוט ודוגמאות ***